



ЦЕНТР
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
МГТУ им. Н.Э. Баумана

Прогнозирование конечных свойств новых материалов (композиционных материалов)

Слушатель: _____

Цель и задачи

- Прогноз двух конечных характеристик
- Обратная регрессия отношения матрица–наполнитель
- Оценка без утечки информации
- Воспроизводимое приложение


Исходные данные

- Две таблицы XLSX, INNER JOIN по индексу
- 1023 наблюдения, 13 содержательных полей
- 17 строк X_pir не вошли после JOIN
- Физическая семантика части полей не документирована

Протокол оценки

- Обучение: 716; отложенная оценка: 307
- GridSearchCV: 10 фолдов обучающей части
- StandardScaler оценивается внутри каждого фолда
- Итоговая оценка после фиксации моделей

Протокол обучения и независимой оценки



Ключевое правило

Масштабирование, IQR-границы и параметры модели оцениваются заново внутри fit-части каждого CV-фолда.

Тестовая выборка не влияет на очистку, признаки, семейство модели или гиперпараметры.


Входы прямых задач: 11 признаков; обе конечные характеристики исключены из X.

MLP отношения матрица–наполнитель: 12 входов; сама цель и производные от неё признаки исключены.

Разведочный анализ

- Пропусков нет
- IQR отмечает кандидатов, строки не удалены
- Максимум $|\text{Pearson}| = 0,1191$
- Низкая парная связь не исключает нелинейность

Репрезентативные графики EDA, только train (n=716)



Полные наборы гистограмм, boxplot и scatter-диаграмм сохранены в figures/eda.

Предобработка

- Индекс исключён из признаков
- IQR: прямые задачи $716 \rightarrow 663$
- IQR: отношение $716 \rightarrow 655$
- Границы оцениваются внутри обучающей части фолда
- Выбран вариант без удаления

Сравниваемые модели


- Константная модель и Ridge
- Random Forest и Gradient Boosting
- SVR
- MLPRegressor 12–32–16–1, $\alpha=0,01$
- RMSE — критерий выбора; MAE и R^2 — контроль

Выбор по перекрёстной проверке

- Модуль: константная модель, $3,087 \pm 0,257$ ГПа
- Прочность: Gradient Boosting, $490,209 \pm 23,852$ МПа
- Gradient Boosting лучше в 4 из 10 фолдов
- Парная разность $+0,291 \pm 8,345$ МПа
- MLP 0,935 хуже константной модели 0,906


Отложенная оценка: модуль

- Выбрана константная модель
- RMSE 3,178 ГПа
- MAE 2,556 ГПа
- $R^2 -0,016$
- Испытанные модели не снизили среднюю CV RMSE




Отложенная оценка: прочность

- Выбран Gradient Boosting
- RMSE 471,410 МПа
- MAE 380,152 МПа
- R^2 0,008
- Значимое и устойчивое преимущество не установлено




Нейронная сеть

- MLP 12–32–16–1; 76 эпох
- Восстановлены веса эпохи 35
- RMSE 0,944; MAE 0,777; $R^2 -0,040$
- Хуже константной модели 0,926
- L2-штраф применяется к весам



Интерпретация и ограничения

- Пермутационная важность: 10 повторов
- Ноль константной модели не означает физическую незначимость
- Важность не равна причинному эффекту
- Перенос на новые материалы не проверен



Приложение и воспроизводимость

11 входов → проверка → два сохранённых pipeline → модуль и прочность

Медианы в форме — демонстрационный профиль, а не измеренный образец.

Фиксированы данные, разбиение, зависимости, команды, модели и отчёты.

github.com/fpvcstep

[.../composites-property-prediction](https://github.com/fpvcstep/composites-property-prediction)

Выводы

- Модуль: константная модель, $R^2 -0,016$
- Прочность: Gradient Boosting, $R^2 0,008$
- Обратная регрессия отношения ненадёжна: $R^2 -0,040$
- Перенос на новые материалы не проверен
- Требуются паспорт данных и внешние испытания

Спасибо за внимание