

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**Федеральное государственное автономное образовательное учреждение
высшего образования**

**«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»**

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по курсу

« Наука о данных: профессиональный уровень (Data Science PRO)»

**«Прогнозирование конечных свойств новых материалов
(композиционных материалов)»**

Слушатель

_____ (ФИО)

Москва, 2026

СОДЕРЖАНИЕ

Введение	3
1 Аналитическая часть	4
1.1 Постановка задачи	4
1.2 Описание используемых методов	5
1.3 Разведочный анализ данных	10
2 Практическая часть	11
2.1 Предобработка данных	11
2.2 Разработка и обучение модели	18
2.3 Тестирование модели	20
2.4 Нейронная сеть	24
2.5 Разработка приложения	25
2.6 Создание удалённого репозитория	25
Заключение	26
Библиографический список	27

ВВЕДЕНИЕ

Композиционные материалы позволяют сочетать свойства матрицы и армирующей фазы, однако конечный отклик зависит от состава, структуры и технологии изготовления. Физические испытания остаются источником подтверждённых характеристик, а регрессионные модели могут использовать накопленные наблюдения для предварительной оценки свойств и планирования дальнейших испытаний.

Цель работы — исследовать возможность прогнозирования модуля упругости при растяжении и прочности при растяжении по характеристикам компонентов и технологическим параметрам, а также построить отдельную учебную модель оценки отношения матрица–наполнитель. Для достижения цели выполняются аудит и объединение данных, разведочный анализ, предобработка без утечки информации, сравнение регрессионных методов, разработка нейросетевой модели и демонстрационного приложения.

Объект исследования — представленные табличные наблюдения о композиционных материалах. Предмет исследования — методы воспроизводимого построения и оценки моделей табличной регрессии. Работа не устанавливает причинные зависимости, не определяет физический паспорт набора и не заменяет лабораторные испытания. Смысл отношения матрица–наполнитель как массовой или объёмной величины в исходных материалах не указан.

1 АНАЛИТИЧЕСКАЯ ЧАСТЬ

1.1 Постановка задачи

После строгого INNER JOIN двух исходных таблиц по исходному индексу получены 1023 наблюдения и 13 содержательных полей. Индекс используется только как ключ соединения. Семнадцать строк, присутствующих только в таблице X_nip.xlsx, не вошли в объединённый набор. Пропуски и нечисловые значения отсутствуют.

Решаются три задачи регрессии. Для модуля упругости при растяжении и прочности при растяжении используются 11 входов: обе конечные характеристики исключаются из признаков, чтобы не применять недоступную при прогнозе информацию. Для учебной оценки отношения матрица–наполнитель используются остальные 12 полей, включая две конечные характеристики. Последняя постановка не является оптимизацией рецептуры.

Единицы шага и плотности нашивки, смысл суффикса _2, происхождение наблюдений, наличие повторных серий и типы компонентов не документированы. Эти неопределённости фиксируются как ограничения, а не заполняются предположениями.

Три постановки регрессии и доступные им входы сопоставлены в таблице 1.

Таблица 1 – Постановки регрессии

Цель	Входы	Назначение
1	2	3
Модуль при растяжении, ГПа	11	Прямой прогноз
Прочность при растяжении, МПа	11	Прямой прогноз
Соотношение матрица–наполнитель	12	Учебная оценка MLP

1.2 Описание используемых методов

Полимерный композит объединяет матрицу и армирующую фазу; свойства зависят от долей, ориентации, геометрии, границы раздела и технологии. Матрица связывает армирование и передаёт нагрузку, волокна обычно повышают продольные жёсткость и прочность. Анизотропия означает зависимость отклика от направления испытания относительно армирования [14], [16]. Технология формования влияет на пропитку, отверждение, пористость и качество ламината [8]. Поэтому признаки состава и процесса физически мотивированы, но форма статистической зависимости заранее неизвестна.

Правило смесей может служить физической гипотезой только при известных определениях долей и направления нагрузки. ASTM D3171 различает массовое и объёмное содержание и учитывает пустоты [4]. В учебных данных природа отношения матрица–наполнитель не определена, поэтому его нельзя переводить в долю или выдавать за паспорт состава. Аналогично температура вспышки не переименовывается в температуру отверждения без метаданных.

Модуль характеризует начальную жёсткость, а прочность — предельное напряжение по принятому критерию. ASTM D3039/D3039M, ISO 527-4 и ISO 527-5 задают условия испытаний и показывают роль укладки, подготовки, среды, захватов и скорости [1], [2], [3]. Межлабораторная работа подтверждает необходимость согласованного протокола [21]. Влажность и температура также способны менять свойства, особенно определяемые матрицей [5], [7]. Эти параметры в наборе не задокументированы и рассматриваются как источник необъяснённой вариации.

1.2.1 Базовый уровень и Ridge

Табличная регрессия отображает вектор доступных признаков в числовой прогноз. Индекс строки исключается как нефизический идентификатор. Для прямого прогноза одной конечной характеристики другая также исключается, поскольку при реальном применении она неизвестна. Единый интерфейс `scikit-learn` связывает преобразования, регрессоры, поиск параметров и оценку [19].

Константная модель прогнозирует среднее обучающей цели и задаёт точку сравнения. Конфигурации выбираются по средней ошибке кросс-валидации, после чего зафиксированный выбор один раз оценивается на отложенной части. Ridge минимизирует квадратичную ошибку с L2-штрафом, уменьшая дисперсию коэффициентов при коррелирующих признаках ценой контролируемого смещения [15]. Он быстр и прозрачен, но без конструирования признаков ограничен линейной зависимостью по переданным признакам.

Для Ridge масштабирование необходимо включать в `pipeline`: иначе различие единиц изменяет относительную силу штрафа. Все параметры преобразования оцениваются заново на тренировочной части каждого фолда. Такой `baseline` показывает, достаточно ли линейного сигнала, и помогает не приписывать гибкой модели преимущество, вызванное утечкой или переобучением.

1.2.2 Ансамбли деревьев

Random Forest усредняет деревья, построенные на случайных выборках наблюдений и признаков; исходный алгоритм охватывает и регрессию [6]. Метод выявляет нелинейности и взаимодействия, устойчив к монотонному масштабированию. Его ограничения — слабая экстраполяция, размер ансамбля и менее непосредственная интерпретация. Глубину и минимальные размеры узлов подбирают только на train.

Gradient Boosting последовательно добавляет слабые модели, каждая из которых уменьшает выбранную функцию потерь [13]. Он гибко аппроксимирует нелинейности, но чувствителен к глубине, темпу обучения и числу итераций. Слишком сложная последовательность переобучается, поэтому лес и бустинг сравниваются на одинаковых фолдах и с тем же baseline.

Достоинства и ограничения двух ансамблевых подходов сопоставлены в таблице 2.

Таблица 2 – Сопоставление ансамблевых методов

Метод	Достоинства	Ограничения
1	2	3
Random Forest	Нелинейности, взаимодействия, устойчивое усреднение	Размер модели, слабая экстраполяция
Gradient Boosting	Последовательная коррекция ошибок	Чувствительность к глубине, темпу и числу итераций

1.2.3 SVR и MLP

Метод опорных векторов решает регуляризованную задачу и через ядро строит нелинейную зависимость в неявном пространстве [11]. В SVR зона ϵ задаёт допустимое отклонение, а ошибку формируют точки за её пределами [12]. Метод подходит для выборок умеренного размера, но чувствителен к масштабу, C , ϵ и параметрам ядра; StandardScaler должен обучаться внутри каждого фолда.

MLP чередует линейные преобразования и нелинейные активации. Обратное распространение вычисляет градиенты функции потерь, а оптимизатор обновляет веса [22]. На небольшой табличной выборке сеть гибка, но вариативна и склонна к переобучению. Регуляризация ограничивает сложность; dropout является одним из известных подходов [23], а используемый MLPRegressor применяет L2-штраф, компактную архитектуру и раннюю остановку.

Ни одно семейство нельзя заранее объявить лучшим. Нейросеть выполняет обратную регрессию отношения по заданному полному профилю, включая механические свойства. Это принятая математическая трактовка рекомендации, но не физическая оптимизация состава: управляемые переменные, ограничения, причинность и экспериментальная проверка отсутствуют.

1.2.4 Оценка качества, утечки и интерпретация

Отложенные 30% используются один раз после выбора, а десятифолдовая CV выполняется только на обучающей части [17]. GridSearchCV перебирает фиксированную сетку [26]; преобразования помещаются в pipeline, поскольку обработка до разделения переносит информацию из проверки [25]. CV для выбора не является независимой итоговой оценкой [24], [9].

MAE — среднее абсолютное отклонение [27], RMSE сильнее реагирует на крупные промахи [30], R^2 сравнивает ошибки с отклонениями от среднего и может быть отрицательным [29], [10]. Метрики приводятся отдельно без универсального порога приемлемости. Пермутационная важность описывает поведение модели, а не причинный механизм [28].

$$RMSE = \sqrt{[(1/n)\sum_{i=1}^n (y_i - \hat{y}_i)^2]}. \quad (1)$$

$$MAE = (1/n)\sum_{i=1}^n |y_i - \hat{y}_i|. \quad (2)$$

$$R^2 = 1 - \sum_{i=1}^n (y_i - \hat{y}_i)^2 / \sum_{i=1}^n (y_i - \bar{y})^2. \quad (3)$$

Здесь n — число наблюдений оцениваемой выборки, y_i и $\hat{y}_i$ — фактическое и прогнозное значения, а $\bar{y}$ — среднее y именно этой выборки. Поэтому константная модель, обученная на среднем обучающей части, может иметь отрицательный R^2 на отложенной части.

Используемые метрики и смысл каждой из них приведены в таблице 3.

Таблица 3 – Метрики регрессии

Метрика	Интерпретация
1	2
RMSE	Ошибка в единицах цели с повышенным весом крупных промахов
MAE	Среднее абсолютное отклонение в единицах цели
R^2	Сравнение с прогнозом среднего; на тесте может быть отрицательным


1.3 Разведочный анализ данных

EDA выполнен только на 716 строках train; 307 test-наблюдений не использовались для статистик, графиков и правил обработки. Анализ включает описательные статистики, гистограммы, диаграммы размаха и рассеяния, Pearson и Spearman. Пропусков нет; угол нашивки принимает 0 и 90 градусов (356 и 360 строк). IQR отмечает кандидатов, но строки не удаляются.

Максимум $|\text{Pearson}|$ равен 0,119 для угла и плотности нашивки. Низкие парные коэффициенты не исключают нелинейную или совместную информацию; вывод о качестве ограничен испытанными моделями и сетками.

Репрезентативные графики train приведены на рисунке 1; полный комплект EDA доступен в репозитории.

Репрезентативные графики EDA, только train (n=716)



Полные наборы гистограмм, boxplot и scatter-диаграмм сохранены в figures/eda.

Рисунок 1 – Репрезентативные распределение, диаграмма размаха и диаграмма рассеяния

2 ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1 Предобработка данных

Исходные файлы проверены по листам, полям, типам и уникальности индекса, затем объединены INNER JOIN один-к-одному. 1023 строки один раз разделены при random_state=42 на train 716 и test 307. Индекс исключён; температура вспышки не переименовывается в температуру отверждения, а физически неподтверждённые доли не создаются.

Ключевые результаты аудита сведены в таблицу 4.

Таблица 4 – Аудит и разбиение данных

Строк	Полей	Train	Test	Пропуски	Seed
1	2	3	4	5	6
1023	13	716	307	0	42

2.1.1 Статистики, выбросы и корреляции

Полные статистики 13 полей сохранены в reports/eda/summary.csv; min/max train указаны на пяти следующих панелях. Редкость не доказывает ошибку.

Больше всего IQR-кандидатов: Плотность нашивки — 16; Количество отвердителя, м.% — 9; Температура вспышки, C_2 — 8.

Для количества отвердителя 468 из 716 train-значений с обозначением «м.%» превышают 100; диапазон равен 17,740–198,953. База процентов в исходных материалах не указана, поэтому эти значения сохранены и не объявляются ошибочными или синтетическими.

Сильнейшая связь train: pearson, Угол нашивки, град / Плотность нашивки, 0.119. Это описательный результат без причинной трактовки и отбора по test.

2.1.2 Распределения до и после нормализации

MinMaxScaler обучен на 716 обучающих строках только для иллюстрации 13 полей. Модели не используют эти преобразованные данные: StandardScaler для X и, где предусмотрено, для y оценивается внутри каждого фолда Ridge, SVR и MLP; деревья получают исходный масштаб.

На рисунке 2 сопоставлены отношение компонентов, плотность и модуль упругости. После линейного преобразования в диапазон $[0; 1]$ сохраняются форма распределения, асимметрия и взаимный порядок наблюдений; различие физических единиц устраняется только для сопоставления графиков.

Распределения train до и после нормализации, $n=716$




Рисунок 2 – Распределения до и после нормализации: Соотношение матрица-наполнитель; Плотность, кг/м3; модуль упругости, ГПа

2.1.2 Распределения до и после нормализации (продолжение)

На рисунке 3 представлены количество отвердителя, содержание эпоксидных групп и температура вспышки. Масштабирование не устраняет длинные хвосты и не меняет неопределённую семантику исходных единиц; значения не получают новой физической трактовки.

Распределения train до и после нормализации, n=716




Рисунок 3 – Распределения до и после нормализации: Количество отвердителя, м.%; Содержание эпоксидных групп,%_2; Температура вспышки, С_2

2.1.2 Распределения до и после нормализации (продолжение)

На рисунке 4 показаны поверхностная плотность и две целевые механические характеристики. Их диапазоны различаются, а преобразование лишь переводит каждую переменную в общую числовую шкалу; цели не смешиваются и оцениваются отдельно.

Распределения train до и после нормализации, n=716




Рисунок 4 – Распределения до и после нормализации: Поверхностная плотность, г/м²; Модуль упругости при растяжении, ГПа; Прочность при растяжении, МПа

2.1.2 Распределения до и после нормализации (продолжение)

На рисунке 5 сопоставлены потребление смолы и бинарный угол нашивки. Угол сохраняет два уровня, соответствующие 0° и 90° ; непрерывная интерпретация промежуточных углов из этих данных невозможна.

Распределения train до и после нормализации, $n=716$




Рисунок 5 – Распределения до и после нормализации: Потребление смолы, г/м2;
Угол нашивки, град

2.1.2 Распределения до и после нормализации (продолжение)

На рисунке 6 показаны шаг и плотность нашивки. Неизвестные единицы ограничивают физическое толкование, однако линейное масштабирование сохраняет наблюдавшиеся относительные различия. Эти иллюстрационные преобразования не используются при обучении моделей.

Распределения train до и после нормализации, n=716




Рисунок 6 – Распределения до и после нормализации: Шаг нашивки; Плотность нашивки

2.1.3 Решения по предобработке

Пропуски отсутствуют, поэтому обязательная импутация не требуется. Масштабирование необходимо для Ridge, SVR и MLP и включается в pipeline. Деревья решений не требуют масштабирования для разбиений, однако оцениваются в том же протоколе.

Выполнено сравнение вариантов без удаления и с IQR-фильтрацией. На полном обучающем наборе фильтр по 11 входам исключал 53 из 716 строк для обеих прямых задач (оставалось 663), а по 12 входам обратной регрессии отношения — 61 строку (оставалось 655); для MLP CV RMSE изменилась с 0,935319 до 0,937889. Границы в каждом фолде оценивались только на его обучающей части, X и y фильтровались синхронно, а validation и test не удалялись. По средней CV RMSE для выбранных моделей сохранён вариант без удаления.

Метаданные не подтверждают экспериментальные группы. Поэтому используется случайное разбиение, а невозможность проверить групповую независимость фиксируется как ограничение.

2.2 Разработка и обучение модели

Для прямых целей сравниваются константная модель, Ridge, Random Forest, Gradient Boosting и SVR; для отношения — константная модель и MLPRegressor. GridSearchCV с десятью фолдами работает только на 716 обучающих строках. Обучаемые преобразования находятся внутри pipeline, основной критерий — средняя RMSE, дополнительно сохраняются MAE и R^2 ; random_state=42.

Выбор зафиксирован до оценки на отложенной части: для модуля — константная модель, для прочности — Gradient Boosting. Последний лучше константной модели в 4 из 10 фолдов, а константная модель — в 6; средняя парная разность RMSE равна +0,291 МПа при стандартном отклонении 8,345 МПа. Формальная значимость превосходства не установлена.

Разделение отложенного test и обучение преобразований внутри CV показаны на рисунке 7.



Рисунок 7 – Разделение test и обучение обработки внутри перекрёстной проверки

Сетки: Ridge $\alpha \in \{0,01; 0,1; 1; 10; 100\}$; Random Forest — (n_estimators, max_depth, min_samples_leaf) $\in \{(200, \text{None}, 1), (150, \text{None}, 3), (200, 10, 1), (150, 10, 3)\}$; Gradient Boosting — learning_rate $\in \{0,03; 0,1\}$, max_depth $\in \{2; 3\}$, n_estimators=150; SVR — C $\in \{0,3; 1; 3\}$, epsilon $\in \{0,05; 0,1\}$, gamma=scale. Проверены варианты без удаления и с IQR-фильтрацией.

Зафиксированные до открытия test конфигурации перечислены в таблице 5.

Таблица 5 – Зафиксированные конфигурации

Цель	Модель	Вариант	Параметры
1	2	3	4
Модуль при растяжении	DummyRegressor(mean)	raw	без гиперпараметров
Прочность при растяжении	Gradient Boosting	raw	learning_rate=0,03; max_depth=2; n_estimators=150
Соотношение матрица–наполнитель	MLPRegressor	raw	hidden=(32,16); alpha=0,01

2.2.1 Результаты перекрёстной проверки

Таблица 6 отражает выбор по обучающей части; отложенные значения не участвовали в ранжировании. Для модуля выбрана константная модель. Для прочности Gradient Boosting лучше в 4 из 10 фолдов, константная модель — в 6; средняя парная разность RMSE равна +0,291 МПа при SD 8,345 МПа. Формальная значимость не установлена. MLP уступает константной модели.

Таблица 6 – Ключевые результаты 10-fold CV

Задача	Семейство	CV RMSE $\pm$ std	CV MAE	CV R ²
1	2	3	4	5
Модуль, ГПа	baseline	3.087 $\pm$ 0.257	2.483	-0.015
Прочность, МПа	baseline	490.500 $\pm$ 24.618	384.750	-0.011
Прочность, МПа	gradient_boosting	490.209 $\pm$ 23.852	387.225	-0.010
Отношение (база не указана)	baseline	0.906 $\pm$ 0.047	0.719	-0.008
Отношение (база не указана)	mlp	0.935 $\pm$ 0.058	0.751	-0.072

2.3 Тестирование классических моделей

В таблице 7 звёздочкой отмечены конфигурации, выбранные до открытия test. RMSE и MAE указаны в единицах цели соответствующей строки; R^2 безразмерен. Для модуля ни одно сложное семейство не улучшило baseline. Для прочности Gradient Boosting получил test RMSE 471,410 МПа против 473,288 МПа baseline, но R^2 остался около нуля.

Таблица 7 – Train/test ошибки пяти семейств для двух прямых задач

Цель	Семейство	Train RMSE	Test RMSE	Test MAE	Test R^2
1	2	3	4	5	6
Модуль, ГПа	baseline*	3,095	3,178	2,556	-0,016
Модуль, ГПа	ridge	3,066	3,190	2,567	-0,024
Модуль, ГПа	gradient_boosting	2,867	3,221	2,587	-0,044
Модуль, ГПа	random_forest	1,817	3,311	2,643	-0,104
Модуль, ГПа	svr	2,813	3,263	2,623	-0,072
Прочность, МПа	baseline	490,497	473,288	378,984	-0,000
Прочность, МПа	ridge	485,154	471,726	378,437	0,006
Прочность, МПа	gradient_boosting*	447,149	471,410	380,152	0,008
Прочность, МПа	random_forest	298,601	476,225	381,814	-0,013
Прочность, МПа	svr	446,934	484,995	390,329	-0,050

Random Forest показывает большой разрыв train/test в обеих задачах.

Низкие и отрицательные test R^2 не позволяют заявлять промышленную точность.

2.3.1 Фактические и прогнозные значения

На рисунке 8 показаны train и test двух прямых задач. Близость к диагонали означала бы точный прогноз; почти постоянный прогноз baseline-модуля и облако прочности показывают ограниченную объясняющую способность.




Рисунок 8 – Фактические и прогнозные значения модуля и прочности

2.3.2 Анализ остатков

Остаток определён как фактическое значение минус прогноз. На рисунке 9 представлены остатки обучающей и отложенной частей двух прямых задач. Их широкий разброс указывает на ограниченную точность испытанных моделей и сеток на данной таблице, но сам по себе не доказывает физического отсутствия зависимости.




Рисунок 9 – Остатки моделей модуля и прочности на train и test

2.3.3 Пермутационная важность и ограничения

Permutation importance рассчитана на test по росту RMSE после перестановки признака, 10 повторов, seed 42; для модели прочности результат дан на рисунке 10. Для baseline-модуля все значения равны нулю: постоянная модель не использует признаки. Это не доказывает их физическую незначимость; отрицательные оценки не трактуются как причинный эффект.

SHAP является отдельным теоретическим подходом к аддитивному объяснению локальных прогнозов [18]; в данном исследовании рассчитана именно пермутационная важность, поэтому эти методы не смешиваются.




Рисунок 10 – Пермутационная важность модели прочности

Неизвестны происхождение наблюдений и группы опытов; поэтому случайный holdout характеризует только данную выборку. Результаты не заменяют лабораторные испытания.

2.4 Нейронная сеть

Выбрана MLPRegressor 12–32–16–1 без удаления IQR-кандидатов, с ReLU, Adam, alpha=0,01 и ранней остановкой. Квадратичная ошибка вычисляется для стандартизованной цели, L2-штраф применяется к весам. CV RMSE равна $0,935 \pm 0,058$ против $0,906 \pm 0,047$ у константной модели.

Обучение завершилось после 76 эпох с восстановлением весов эпохи 35. Из 716 строк 644 обновляют веса, 72 используются для ранней остановки; масштабирование X/y оценено до этого разбиения, поэтому внутренняя кривая не полностью независима, а внешние фолды и отложенная часть изолированы. random_state 42–44 меняет веса, внутреннее разбиение и мини-батчи.

Обратная регрессия оценивает отношение по полному профилю, включая заданные механические свойства. Из-за проигрыша константной модели, отсутствия причинности и физической проверки результат нельзя считать надёжной рекомендацией рецептуры.

Ошибки MLP и baseline сопоставлены в таблице 8, а ход обучения и устойчивость CV показаны на рисунке 11.

Таблица 8 – Ошибки baseline и MLP

Семейство	Train RMSE	Test RMSE	Test MAE	Test R ²
1	2	3	4	5
baseline	0,907	0,926	0,752	-0,001
mlp*	0,870	0,944	0,777	-0,040




Рисунок 11 – Диагностика обучения MLP и вариативность CV при трёх random_state

2.5 Разработка и использование приложения

Интерфейс проверяет 11 признаков, загружает два pipeline и выводит модуль и прочность. Для медианных входов получены 73,2073 ГПа и 2502,06 МПа — демонстрация условного профиля, а не измеренный образец.

Для запуска нужны Docker Desktop и Linux containers. Из корня выполняют `docker build -t composites-thesis:local .`, затем `docker run --rm -p 127.0.0.1:8501:8501 -v "${PWD}:/workspace:ro" -w /workspace composites-thesis:local streamlit run app/streamlit_app.py --server.address=0.0.0.0`. Открыв <http://localhost:8501>, вводят 11 характеристик и нажимают «Прогноз»; выход за train min/max вызывает предупреждение об экстраполяции.

2.6 Создание удалённого репозитория и загрузка результатов

Воспроизводимость требует фиксировать исходные данные, способ объединения, версии зависимостей, разбиение, `random_state`, последовательность преобразований, поиск гиперпараметров, метрики и сохранённые модели [20]. Профиль автора: <https://github.com/fpvctest>. Публичный репозиторий: <https://github.com/fpvctest/composites-property-prediction>; история изменений: <https://github.com/fpvctest/composites-property-prediction/commits/main>.

Исследование воспроизводится последовательными командами аудита, подготовки данных, разведочного анализа, обучения и итоговой оценки, указанными в README. Зафиксированные разбиение и версии зависимостей связывают опубликованные таблицы, рисунки и модели с исходными файлами. Контейнер собирается по Dockerfile; изменяемый тег базового образа и незакреплённая версия `pip` ограничивают архивную воспроизводимость среды.

ЗАКЛЮЧЕНИЕ

Проверены две исходные таблицы и объединены 1023 наблюдения. Разбиение 716/307 отделяет выбор решений от итоговой оценки. В обучающей части нет пропусков и полных дубликатов; максимум $|\text{Pearson}|$ равен 0,119. Кандидаты по правилу 1,5 IQR не признаны ошибками без предметного основания.

IQR-фильтрация оставляла 663 строки для обеих прямых задач и 655 для обратной регрессии, но не улучшила выбранные конфигурации по средней CV RMSE. Для модуля среди испытанных моделей выбрана константа; на отложенной части RMSE равна 3,178 ГПа, MAE 2,556 ГПа, $R^2 -0,016$.

Для прочности выбран Gradient Boosting. Он лучше константной модели в 4 из 10 фолдов; парная разность RMSE равна $+0,291 \pm 8,345$ МПа. На отложенной части RMSE составляет 471,410 МПа, MAE 380,152 МПа, $R^2 0,008$. Значимое устойчивое превосходство не установлено.

MLP 12–32–16–1 оценивает отношение по полному профилю, но уступает константной модели: RMSE 0,944 и $R^2 -0,040$. Без причинной и экспериментальной проверки обратная регрессия не является надёжной рекомендацией рецептуры. Приложение демонстрирует два прямых прогноза и предупреждает о выходе за обучающие диапазоны.

Команды, разбиение, версии зависимостей, таблицы, рисунки и модели обеспечивают проверяемость. Выводы относятся к случайно отложенным строкам этой таблицы: происхождение, группы опытов и часть единиц неизвестны, внешняя проверка отсутствует. Нужны паспорт данных, групповое или внешнее испытание и новые лабораторные наблюдения; до этого прогнозы не заменяют измерения.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1 ASTM International. ASTM D3039/D3039M-17(2025): Standard Test Method for Tensile Properties of Polymer Matrix Composite Materials. 2025. DOI: 10.1520/D3039_D3039M-17R25.

2 International Organization for Standardization. ISO 527-4:2023 Plastics — Determination of tensile properties — Part 4: Test conditions for isotropic and orthotropic fibre-reinforced plastic composites. ISO, 2023. <https://www.iso.org/standard/85809.html>. Дата обращения: 24.09.2026.

3 International Organization for Standardization. ISO 527-5:2021 Plastics — Determination of tensile properties — Part 5: Test conditions for unidirectional fibre-reinforced plastic composites. ISO, 2021. <https://www.iso.org/standard/80370.html>. Дата обращения: 24.09.2026.

4 ASTM International. ASTM D3171-22: Standard Test Methods for Constituent Content of Composite Materials. 2022. DOI: 10.1520/D3171-22.

5 ASTM International. ASTM D5229/D5229M-20: Standard Test Method for Moisture Absorption Properties and Equilibrium Conditioning of Polymer Matrix Composite Materials. 2020. DOI: 10.1520/D5229_D5229M-20.

6 Breiman L. Random Forests. Machine Learning 45, 5–32, 2001. DOI: 10.1023/A:1010933404324.

7 Browning C.E., Husman G.E., Whitney J.M. Moisture Effects in Epoxy Matrix Composites. Composite Materials: Testing and Design (Fourth Conference), ASTM STP 617, 1977, pp. 481–496. DOI: 10.1520/STP26961S.

8 Campbell F.C. Manufacturing Processes for Advanced Composites. Elsevier Science, 2003. DOI: 10.1016/B978-1-85617-415-2.X5000-X.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК (продолжение)

9 Cawley G.C., Talbot N.L.C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. *Journal of Machine Learning Research* 11, 2079–2107, 2010. <https://www.jmlr.org/papers/v11/cawley10a.html>.

Дата обращения: 24.09.2026.

10 Chicco D., Warrens M.J., Jurman G. The Coefficient of Determination R-squared Is More Informative than SMAPE, MAE, MAPE, MSE and RMSE in Regression Analysis Evaluation. *PeerJ Computer Science* 7:e623, 2021. DOI: 10.7717/peerj-cs.623.

11 Cortes C., Vapnik V. Support-Vector Networks. *Machine Learning* 20, 273–297, 1995. DOI: 10.1007/BF00994018.

12 Drucker H., Burges C.J.C., Kaufman L. et al. Support Vector Regression Machines. *Advances in Neural Information Processing Systems* 9, 1996. <https://papers.nips.cc/paper/1996/hash/d38901788c533e8286cb6400b40b386d-Abstract.html>. Дата обращения: 24.09.2026.

13 Friedman J.H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics* 29(5), 1189–1232, 2001. DOI: 10.1214/aos/1013203451.

14 Gibson R.F. *Principles of Composite Material Mechanics*. CRC Press, 2016. <https://www.routledge.com/Principles-of-Composite-Material-Mechanics-Fourth-Edition-4th-Edition/Gibson/p/book/9781498720694>. Дата обращения: 24.09.2026.

15 Hoerl A.E., Kennard R.W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics* 12(1), 55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

16 Jones F.R. *Composites Science, Technology, and Engineering*. Cambridge University Press, 2022. DOI: 10.1017/9781139565943.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК (продолжение)

17 Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. Proceedings of IJCAI 1995, 1137–1143. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>. Дата обращения: 24.09.2026.

18 Lundberg S.M., Lee S. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems 30, 2017. <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>. Дата обращения: 24.09.2026.

19 Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research 12, 2825–2830, 2011. <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Дата обращения: 24.09.2026.

20 Pineau J., Vincent-Lamarre P., Sinha K. et al. Improving Reproducibility in Machine Learning Research: A Report from the NeurIPS 2019 Reproducibility Program. Journal of Machine Learning Research 22(164), 1–20, 2021. <https://jmlr.org/papers/v22/20-303.html>. Дата обращения: 24.09.2026.

21 Pinnell M., Fields R., Zabora R. Results of an Interlaboratory Study of the ASTM Standard Test Method for Tensile Properties of Polymer Matrix Composites D 3039. Journal of Testing and Evaluation 33(1), 2005. DOI: 10.1520/JTE12521.

22 Rumelhart D.E., Hinton G.E., Williams R.J. Learning Representations by Back-propagating Errors. Nature 323, 533–536, 1986. DOI: 10.1038/323533a0.

23 Srivastava N., Hinton G., Krizhevsky A. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research 15, 1929–1958, 2014. <https://www.jmlr.org/papers/v15/srivastava14a.html>. Дата обращения: 24.09.2026.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК (продолжение)

24 Varma S., Simon R. Bias in Error Estimation When Using Cross-Validation for Model Selection. BMC Bioinformatics 7, 91, 2006. DOI: 10.1186/1471-2105-7-91.

25 scikit-learn developers. Common Pitfalls and Recommended Practices. scikit-learn documentation, 2026. https://scikit-learn.org/stable/common_pitfalls.html.
Дата обращения: 24.09.2026.

26 scikit-learn developers. GridSearchCV API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html.
Дата обращения: 24.09.2026.

27 scikit-learn developers. mean_absolute_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html.
Дата обращения: 24.09.2026.

28 scikit-learn developers. Permutation Feature Importance. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/permutation_importance.html.
Дата обращения: 24.09.2026.

29 scikit-learn developers. r2_score API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html.
Дата обращения: 24.09.2026.

30 scikit-learn developers. root_mean_squared_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.root_mean_squared_error.html.
Дата обращения: 24.09.2026.