

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
« Наука о данных: профессиональный уровень (Data Science PRO)»

Слушатель _____ (ФИО)

Москва, 2026

СОДЕРЖАНИЕ

Введение	3
1 Аналитическая часть	4
1.1 Постановка задачи	4
1.2 Описание используемых методов	5
1.3 Разведочный анализ данных	10
2 Практическая часть	11
2.1 Предобработка данных	11
2.2 Разработка и обучение модели	18
2.3 Тестирование модели	20
2.4 Нейронная сеть	24
2.5 Разработка приложения	25
2.6 Создание удалённого репозитория	25
Заключение	26
Библиографический список	27

ВВЕДЕНИЕ

Композиционные материалы позволяют сочетать свойства матрицы и армирующей фазы, однако конечный отклик зависит от состава, структуры и технологии изготовления. Физические испытания остаются источником подтверждённых характеристик, а регрессионные модели могут использовать накопленные наблюдения для предварительной оценки свойств и планирования дальнейших испытаний.

Цель работы — исследовать возможность прогнозирования модуля упругости при растяжении и прочности при растяжении по характеристикам компонентов и технологическим параметрам, а также построить отдельную учебную модель оценки отношения матрица–наполнитель. Для достижения цели выполняются аудит и объединение данных, разведочный анализ, предобработка без утечки информации, сравнение регрессионных методов, разработка нейросетевой модели и демонстрационного приложения.

Объект исследования — представленные табличные наблюдения о композиционных материалах. Предмет исследования — методы воспроизводимого построения и оценки моделей табличной регрессии. Работа не устанавливает причинные зависимости, не определяет физический паспорт набора и не заменяет лабораторные испытания. Смысл отношения матрица–наполнитель как массовой или объёмной величины в исходных материалах не указан.

1 АНАЛИТИЧЕСКАЯ ЧАСТЬ

1.1 Постановка задачи

После строгого INNER JOIN двух исходных таблиц по исходному индексу получены 1023 наблюдения и 13 содержательных полей. Индекс используется только как ключ соединения. Семнадцать строк, присутствующих только в таблице X_nip.xlsx, не вошли в объединённый набор. Пропуски и нечисловые значения отсутствуют.

Решаются три задачи регрессии. Для модуля упругости при растяжении и прочности при растяжении используются 11 входов: обе конечные характеристики исключаются из признаков, чтобы не применять недоступную при прогнозе информацию. Для учебной оценки отношения матрица–наполнитель используются остальные 12 полей, включая две конечные характеристики. Последняя постановка не является оптимизацией рецептуры.

Единицы шага и плотности нашивки, смысл суффикса _2, происхождение наблюдений, наличие повторных серий и типы компонентов не документированы. Эти неопределённости фиксируются как ограничения, а не заполняются предположениями.

Три постановки регрессии и доступные им входы сопоставлены в таблице 1.

Таблица 1 – Постановки регрессии

Цель	Входы	Назначение
1	2	3
Модуль при растяжении, ГПа	11	Прямой прогноз
Прочность при растяжении, МПа	11	Прямой прогноз
Соотношение матрица–наполнитель	12	Учебная оценка MLP

1.2 Описание используемых методов

Полимерный композит объединяет матрицу и армирующую фазу; свойства зависят от долей, ориентации, геометрии, границы раздела и технологии. Матрица связывает армирование и передаёт нагрузку, волокна обычно повышают продольные жёсткость и прочность. Анизотропия означает зависимость отклика от направления испытания относительно армирования [14], [16]. Технология формования влияет на пропитку, отверждение, пористость и качество ламината [8]. Поэтому признаки состава и процесса физически мотивированы, но форма статистической зависимости заранее неизвестна.

Правило смесей может служить физической гипотезой только при известных определениях долей и направления нагрузки. ASTM D3171 различает массовое и объёмное содержание и учитывает пустоты [4]. В учебных данных природа отношения матрица–наполнитель не определена, поэтому его нельзя переводить в долю или выдавать за паспорт состава. Аналогично температура вспышки не переименовывается в температуру отверждения без метаданных.

Модуль характеризует начальную жёсткость, а прочность — предельное напряжение по принятому критерию. ASTM D3039/D3039M, ISO 527-4 и ISO 527-5 задают условия испытаний и показывают роль укладки, подготовки, среды, захватов и скорости [1], [2], [3]. Межлабораторная работа подтверждает необходимость согласованного протокола [21]. Влажность и температура также способны менять свойства, особенно определяемые матрицей [5], [7]. Эти параметры в наборе не задокументированы и рассматриваются как источник необъяснённой вариации.

1.2 Описание используемых методов: базовый уровень и Ridge

Табличная регрессия отображает вектор доступных признаков в числовой прогноз. Индекс строки исключается как нефизический идентификатор. Для прямого прогноза одной конечной характеристики другая также исключается, поскольку при реальном применении она неизвестна. Единый интерфейс `scikit-learn` связывает преобразования, регрессоры, поиск параметров и оценку [19].

Константный `baseline` прогнозирует среднее `train` и задаёт минимально необходимую точку сравнения. Сложная модель обоснована только при устойчивом снижении ошибки на неизменном `test`. `Ridge` минимизирует квадратичную ошибку с L2-штрафом, уменьшая дисперсию коэффициентов при коррелирующих признаках ценой контролируемого смещения [15]. Он быстр и прозрачен, но без конструирования признаков ограничен почти линейной зависимостью.

Для `Ridge` масштабирование необходимо включать в `pipeline`: иначе различие единиц изменяет относительную силу штрафа. Все параметры преобразования оцениваются заново на тренировочной части каждого фолда. Такой `baseline` показывает, достаточно ли линейного сигнала, и помогает не приписывать гибкой модели преимущество, вызванное утечкой или переобучением.

1.2 Описание используемых методов: ансамбли деревьев

Random Forest усредняет деревья, построенные на случайных выборках наблюдений и признаков; исходный алгоритм охватывает и регрессию [6]. Метод выявляет нелинейности и взаимодействия, устойчив к монотонному масштабированию. Его ограничения — слабая экстраполяция, размер ансамбля и менее непосредственная интерпретация. Глубину и минимальные размеры узлов подбирают только на train.

Gradient Boosting последовательно добавляет слабые модели, каждая из которых уменьшает выбранную функцию потерь [13]. Он гибко аппроксимирует нелинейности, но чувствителен к глубине, темпу обучения и числу итераций. Слишком сложная последовательность переобучается, поэтому лес и бустинг сравниваются на одинаковых фолдах и с тем же baseline.

Достоинства и ограничения двух ансамблевых подходов сопоставлены в таблице 2.

Таблица 2 – Сопоставление ансамблевых методов

Метод	Достоинства	Ограничения
1	2	3
Random Forest	Нелинейности, взаимодействия, устойчивое усреднение	Размер модели, слабая экстраполяция
Gradient Boosting	Последовательная коррекция ошибок	Чувствительность к глубине, темпу и числу итераций

1.2 Описание используемых методов: SVR и MLP

Метод опорных векторов решает регуляризованную задачу и через ядро строит нелинейную зависимость в неявном пространстве [11]. В SVR зона ϵ задаёт допустимое отклонение, а ошибку формируют точки за её пределами [12]. Метод подходит для выборок умеренного размера, но чувствителен к масштабу, C , ϵ и параметрам ядра; StandardScaler должен обучаться внутри каждого фолда.

MLP чередует линейные преобразования и нелинейные активации, а обратное распространение вычисляет изменение весов для уменьшения потерь [22]. На небольшой табличной выборке сеть гибка, но вариативна и склонна к переобучению. Регуляризация ограничивает сложность; dropout является одним из известных подходов [23], а используемый MLPRegressor применяет L2-штраф, компактную архитектуру и раннюю остановку.

Ни одно семейство нельзя заранее объявить лучшим. Ridge проверяет линейный сигнал, лес усредняет деревья, бустинг последовательно исправляет ошибки, а SVR и MLP требуют особенно аккуратного масштаба. Сравнение учитывает среднее и разброс ошибок по фолдам, разрыв train/test и устойчивость. Нейросеть оценивает наблюдаемое отношение, но не решает обратную задачу и не оптимизирует физический состав.

1.2 Оценка качества, утечки и интерпретация

Отложенные 30% используются один раз после выбора, а десятифолдовая CV выполняется только на train. Число фолдов связано с компромиссом смещения и дисперсии оценки [17]. GridSearchCV перебирает фиксированную сетку [26], а обучаемые преобразования помещаются в pipeline: обработка до разделения переносит информацию из проверки и завышает качество [25]. CV, использованная для выбора, не является независимой итоговой оценкой [24], [9].

MAE — среднее абсолютное отклонение [27]; RMSE сильнее реагирует на крупные промахи [30]; R^2 сравнивает модель с прогнозом среднего и может быть отрицательным [29]. R^2 информативен [10], но не заменяет ошибки в ГПа или МПа. Поэтому все три метрики приводятся отдельно для train/test без универсального порога приемлемости.

SHAP формирует аддитивные локальные вклады [18], а permutation importance измеряет ухудшение качества после перестановки столбца [28]. Оба метода описывают поведение модели, а не причинный механизм. Коррелирующие признаки могут делить информацию, а отрицательная пермутационная оценка возможна из-за вариативности ограниченного test.

Используемые метрики и смысл каждой из них приведены в таблице 3.

Таблица 3 – Метрики регрессии

Метрика	Интерпретация
1	2
RMSE	Ошибка в единицах цели с повышенным весом крупных промахов
MAE	Среднее абсолютное отклонение в единицах цели
R^2	Сравнение с прогнозом среднего; на тесте может быть отрицательным

1.3 Разведочный анализ данных

EDA выполнен только на 716 строках train; 307 test-наблюдений не использовались для статистик, графиков и правил обработки. Анализ включает описательные статистики, гистограммы, диаграммы размаха и рассеяния, Pearson и Spearman. Пропусков нет; угол нашивки принимает 0 и 90 градусов (356 и 360 строк). IQR отмечает кандидатов, но строки не удаляются.

Максимум $|\text{Pearson}|$ равен 0,1190618657 для угла и плотности нашивки. Низкие парные коэффициенты не исключают нелинейную или совместную информацию; вывод о моделируемости делается по оценке моделей.

Репрезентативные графики train приведены на рисунке 1; полный комплект EDA доступен в репозитории.

Репрезентативные графики EDA, только train (n=716)




Рисунок 1 – Репрезентативные распределение, диаграмма размаха и диаграмма рассеяния

2 ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1 Предобработка данных

Исходные файлы проверены по листам, полям, типам и уникальности индекса, затем объединены INNER JOIN один-к-одному. 1023 строки один раз разделены при random_state=42 на train 716 и test 307. Индекс исключён; температура вспышки не переименовывается в температуру отверждения, а физически неподтверждённые доли не создаются.

Ключевые результаты аудита сведены в таблицу 4.

Таблица 4 – Аудит и разбиение данных

Строк	Полей	Train	Test	Пропуски	Seed
1	2	3	4	5	6
1023	13	716	307	0	42

2.1 Статистики, выбросы и корреляции

Полные статистики 13 полей сохранены в reports/eda/summary.csv; min/max train указаны на пяти следующих панелях. Редкость не доказывает ошибку.

Больше всего IQR-кандидатов: Плотность нашивки — 16; Количество отвердителя, м.% — 9; Температура вспышки, C_2 — 8.

Для количества отвердителя 468 из 716 train-значений с обозначением «м.%» превышают 100; диапазон равен 17,740–198,953. База процентов в исходных материалах не указана, поэтому эти значения сохранены и не объявляются ошибочными или синтетическими.

Сильнейшая связь train: pearson, Угол нашивки, град / Плотность нашивки, 0.119. Это описательный результат без причинной трактовки и отбора по test.

2.1 Распределения до и после нормализации

На рисунке 2 показаны реальные распределения train. MinMaxScaler обучен на train только для иллюстрации 13 полей. Ни одна модель не обучается на этих MinMax-преобразованных данных: StandardScaler для X и, где предусмотрено, для y находится внутри CV-pipeline Ridge, SVR и MLP; деревья получают исходный масштаб.

Распределения train до и после нормализации, $n=716$




Рисунок 2 – Распределения до и после нормализации: Соотношение матрица-наполнитель; Плотность, кг/м3; модуль упругости, ГПа

2.1 Распределения до и после нормализации

На рисунке 3 показаны реальные распределения train. MinMaxScaler обучен на train только для иллюстрации 13 полей. Ни одна модель не обучается на этих MinMax-преобразованных данных: StandardScaler для X и, где предусмотрено, для y находится внутри CV-pipeline Ridge, SVR и MLP; деревья получают исходный масштаб.

Распределения train до и после нормализации, n=716




Рисунок 3 – Распределения до и после нормализации: Количество отвердителя, м.%; Содержание эпоксидных групп,%_2; Температура вспышки, С_2

2.1 Распределения до и после нормализации

На рисунке 4 показаны реальные распределения train. MinMaxScaler обучен на train только для иллюстрации 13 полей. Ни одна модель не обучается на этих MinMax-преобразованных данных: StandardScaler для X и, где предусмотрено, для y находится внутри CV-pipeline Ridge, SVR и MLP; деревья получают исходный масштаб.

Распределения train до и после нормализации, $n=716$




Рисунок 4 – Распределения до и после нормализации: Поверхностная плотность, г/м²; Модуль упругости при растяжении, ГПа; Прочность при растяжении, МПа

2.1 Распределения до и после нормализации

На рисунке 5 показаны реальные распределения train. MinMaxScaler обучен на train только для иллюстрации 13 полей. Ни одна модель не обучается на этих MinMax-преобразованных данных: StandardScaler для X и, где предусмотрено, для y находится внутри CV-pipeline Ridge, SVR и MLP; деревья получают исходный масштаб.

Распределения train до и после нормализации, n=716




Рисунок 5 – Распределения до и после нормализации: Потребление смолы, г/м2;
Угол нашивки, град

2.1 Распределения до и после нормализации

На рисунке 6 показаны реальные распределения train. MinMaxScaler обучен на train только для иллюстрации 13 полей. Ни одна модель не обучается на этих MinMax-преобразованных данных: StandardScaler для X и, где предусмотрено, для y находится внутри CV-pipeline Ridge, SVR и MLP; деревья получают исходный масштаб.

Распределения train до и после нормализации, n=716




Рисунок 6 – Распределения до и после нормализации: Шаг нашивки; Плотность нашивки

2.1 Решения по предобработке

Пропуски отсутствуют, поэтому обязательная импутация не требуется. Масштабирование необходимо для Ridge, SVR и MLP и включается в pipeline. Деревья решений не требуют масштабирования для разбиений, однако оцениваются в том же протоколе.

Границы IQR не применяются к тестовой части и не используются как автоматическое доказательство ошибки. Если в модельном эксперименте сравниваются raw и filtered варианты, правило фильтрации обучается только внутри тренировочных фолдов. Итоговый выбор должен опираться на CV, а тест открывается после фиксации конфигурации.

Метаданные не подтверждают экспериментальные группы. Поэтому используется случайное разбиение, а невозможность проверить групповую независимость фиксируется как ограничение.

2.2 Разработка и обучение модели

Для прямых целей сравниваются baseline, Ridge, Random Forest, Gradient Boosting и SVR; для отношения — baseline и MLPRegressor. GridSearchCV с десятью фолдами работает только на 716 строках train. Обучаемые преобразования находятся внутри pipeline, основной критерий — RMSE, дополнительно сохраняются MAE и R^2 ; random_state=42.

Выбор зафиксирован до открытия test: для модуля — baseline, для прочности — Gradient Boosting. Его преимущество по CV RMSE над baseline лишь 0,291 МПа при стандартном отклонении 23,852 МПа.

Разделение отложенного test и обучение преобразований внутри CV показаны на рисунке 7.




Рисунок 7 – Разделение test и обучение обработки внутри перекрёстной проверки

Сетки: Ridge alpha 0,01–100; Random Forest — четыре сочетания; Gradient Boosting — learning_rate 0,03/0,1, max_depth 2/3 и 150 деревьев; SVR — C 0,3/1/3 и epsilon 0,05/0,1. Проверены raw и iqr_filtered варианты.

Зафиксированные до открытия test конфигурации перечислены в таблице 5.

Таблица 5 – Зафиксированные конфигурации

Цель	Модель	Вариант	Параметры
1	2	3	4
Модуль при растяжении	DummyRegressor(mean)	raw	без гиперпараметров
Прочность при растяжении	Gradient Boosting	raw	learning_rate=0,03; max_depth=2; n_estimators=150
Соотношение матрица-наполнитель	MLPRegressor	raw	hidden=(32,16); alpha=0,01

2.2 Результаты перекрёстной проверки

Таблица 6 отражает train-only выбор. Значения test не участвовали в ранжировании. RMSE и MAE выражены в единицах соответствующей строки (ГПа, МПа либо исходная единица отношения с неуказанной базой), R^2 безразмерен. Для модуля выбран baseline; для прочности преимущество Gradient Boosting над baseline по CV RMSE равно 0,291 МПа и мало относительно межфолдового стандартного отклонения 23,852 МПа. MLP уступает baseline.

Таблица 6 – Ключевые результаты 10-fold CV

Задача	Семейство	CV RMSE $\pm$ std	CV MAE	CV R^2
1	2	3	4	5
Модуль, ГПа	baseline	3.087 ± 0.257	2.483	-0.015
Прочность, МПа	baseline	490.500 ± 24.618	384.750	-0.011
Прочность, МПа	gradient_boosting	490.209 ± 23.852	387.225	-0.010
Отношение (база не указана)	baseline	0.906 ± 0.047	0.719	-0.008
Отношение (база не указана)	mlp	0.935 ± 0.058	0.751	-0.072

2.3 Тестирование классических моделей

В таблице 7 звёздочкой отмечены конфигурации, выбранные до открытия test. RMSE и MAE указаны в единицах цели соответствующей строки; R^2 безразмерен. Для модуля ни одно сложное семейство не улучшило baseline. Для прочности Gradient Boosting получил test RMSE 471,410 МПа против 473,288 МПа baseline, но R^2 остался около нуля.

Таблица 7 – Train/test ошибки пяти семейств для двух прямых задач

Цель	Семейство	Train RMSE	Test RMSE	Test MAE	Test R^2
1	2	3	4	5	6
Модуль, ГПа	baseline*	3.095	3.178	2.556	-0.016
Модуль, ГПа	ridge	3.066	3.190	2.567	-0.024
Модуль, ГПа	gradient_boosting	2.867	3.221	2.587	-0.044
Модуль, ГПа	random_forest	1.817	3.311	2.643	-0.104
Модуль, ГПа	svr	2.813	3.263	2.623	-0.072
Прочность, МПа	baseline	490.497	473.288	378.984	-0.000
Прочность, МПа	ridge	485.154	471.726	378.437	0.006
Прочность, МПа	gradient_boosting*	447.149	471.410	380.152	0.008
Прочность, МПа	random_forest	298.601	476.225	381.814	-0.013
Прочность, МПа	svr	446.934	484.995	390.329	-0.050

Random Forest показывает большой разрыв train/test в обеих задачах.

Низкие и отрицательные test R^2 не позволяют заявлять промышленную точность.

2.3.1 Фактические и прогнозные значения

На рисунке 8 показаны train и test двух прямых задач. Близость к диагонали означала бы точный прогноз; почти постоянный прогноз baseline-модуля и облако прочности показывают ограниченную объясняющую способность.





Рисунок 8 – Фактические и прогнозные значения модуля и прочности

2.3.2 Анализ остатков

Остаток определён как фактическое значение минус прогноз. На рисунке 9 представлены train/test остатки двух прямых задач; широкий разброс подтверждает отсутствие устойчивой восстановленной зависимости.



Остатки выбранных моделей: полные train и test



Рисунок 9 – Остатки моделей модуля и прочности на train и test

2.3.3 Пермутационная важность и ограничения

Permutation importance рассчитана на test по росту RMSE после перестановки признака, 10 повторов, seed 42; для модели прочности результат дан на рисунке 10. Для baseline-модуля все значения равны нулю: постоянная модель не использует признаки. Это не доказывает их физическую незначимость; отрицательные оценки не трактуются как причинный эффект.




Рисунок 10 – Пермутационная важность модели прочности

Неизвестны происхождение наблюдений и группы опытов; поэтому случайный holdout характеризует только данную выборку. Результаты не заменяют лабораторные испытания.

2.4 Нейронная сеть

Для отношения матрица–наполнитель выбрана raw MLPRegressor с архитектурой (32, 16), ReLU, Adam, alpha=0,01 и ранней остановкой. CV RMSE равен $0,935 \pm 0,058$, тогда как baseline получил $0,906 \pm 0,047$; нейросеть хуже простого прогноза среднего.

Финальный fit остановился на 76-й итерации без предупреждений сходимости. Seeds 42, 43 и 44 дали близкие CV RMSE около 0,94–0,95; seed не выбирался по test. Потери соответствуют $\frac{1}{2}$ MSE с L2-регуляризацией стандартизированной цели. Оценка наблюдаемого отношения по 12 характеристикам не является физически оптимальной рецептурой или причинной рекомендацией.

Ошибки MLP и baseline сопоставлены в таблице 8, а ход обучения и устойчивость CV показаны на рисунке 11.

Таблица 8 – Ошибки baseline и MLP

Семейство	Train RMSE	Test RMSE	Test MAE	Test R ²
1	2	3	4	5
baseline	0.907	0.926	0.752	-0.001
mlp*	0.870	0.944	0.777	-0.040




Рисунок 11 – Диагностика обучения MLP и устойчивость CV по трём seed

2.5 Разработка и использование приложения

Интерфейс проверяет 11 признаков, загружает два pipeline и выводит модуль и прочность. Для медианных входов получены 73,2073 ГПа и 2502,06 МПа — демонстрация условного профиля, а не измеренный образец.

Для запуска нужны Docker Desktop и Linux containers. Из корня выполняют `docker build -t composites-thesis:local .`, затем `docker run --rm -p 127.0.0.1:8501:8501 -v "${PWD}:/workspace:ro" -w /workspace composites-thesis:local streamlit run app/streamlit_app.py --server.address=0.0.0.0`. Открыв <http://localhost:8501>, вводят 11 характеристик и нажимают «Прогноз»; выход за train min/max вызывает предупреждение об экстраполяции.

2.6 Создание удалённого репозитория и загрузка результатов

Воспроизводимость требует фиксировать данные и INNER JOIN, версии, разбиение, seed, pipeline, поиск, метрики и модели [20]. Публичный репозиторий: <https://github.com/fpvcstep/composites-property-prediction>; коммиты 50ef93f, 2cbd05f и ccb6796. В чистой копии прошли 35 тестов; 24 метрики и 12 276 прогнозов совпали ($\max \Delta=0$).

ЗАКЛЮЧЕНИЕ

Выполнены аудит, INNER JOIN, фиксированное разбиение 716/307 и EDA только на train. Максимум |Pearson| равен 0,1190618657 и сам по себе не определяет моделируемость.

По CV для модуля baseline лучше классических моделей; преимущество Gradient Boosting по прочности всего 0,291 МПа, MLP отношения также уступает baseline. На test выбранные модели получили R^2 -0,016; 0,008 и -0,040. Результаты не подтверждают выбор оптимального состава или промышленную точность.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

- 1 ASTM International. ASTM D3039/D3039M-17(2025): Standard Test Method for Tensile Properties of Polymer Matrix Composite Materials. 2025. DOI: 10.1520/D3039_D3039M-17R25.
- 2 International Organization for Standardization. ISO 527-4:2023 Plastics — Determination of tensile properties — Part 4: Test conditions for isotropic and orthotropic fibre-reinforced plastic composites. ISO, 2023. <https://www.iso.org/standard/85809.html>. Дата обращения: 24.09.2026.
- 3 International Organization for Standardization. ISO 527-5:2021 Plastics — Determination of tensile properties — Part 5: Test conditions for unidirectional fibre-reinforced plastic composites. ISO, 2021. <https://www.iso.org/standard/80370.html>. Дата обращения: 24.09.2026.
- 4 ASTM International. ASTM D3171-22: Standard Test Methods for Constituent Content of Composite Materials. 2022. DOI: 10.1520/D3171-22.
- 5 ASTM International. ASTM D5229/D5229M-20: Standard Test Method for Moisture Absorption Properties and Equilibrium Conditioning of Polymer Matrix Composite Materials. 2020. DOI: 10.1520/D5229_D5229M-20.
- 6 Breiman L.. Random Forests. Machine Learning 45, 5–32, 2001. DOI: 10.1023/A:1010933404324.
- 7 Browning C.E., Husman G.E., Whitney J.M.. Moisture Effects in Epoxy Matrix Composites. Composite Materials: Testing and Design (Fourth Conference), ASTM STP 617, 1977, pp. 481–496, 1977. DOI: 10.1520/STP26961S.
- 8 Campbell F.C.. Manufacturing Processes for Advanced Composites. Elsevier Science, 2003. DOI: 10.1016/B978-1-85617-415-2.X5000-X.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК (продолжение)

9 Cawley G.C., Talbot N.L.C.. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. *Journal of Machine Learning Research* 11, 2079–2107, 2010. <https://www.jmlr.org/papers/v11/cawley10a.html>.

Дата обращения: 24.09.2026.

10 Chicco D., Warrens M.J., Jurman G.. The Coefficient of Determination R-squared Is More Informative than SMAPE, MAE, MAPE, MSE and RMSE in Regression Analysis Evaluation. *PeerJ Computer Science* 7:e623, 2021. DOI: 10.7717/peerj-cs.623.

11 Cortes C., Vapnik V.. Support-Vector Networks. *Machine Learning* 20, 273–297, 1995. DOI: 10.1007/BF00994018.

12 Drucker H., Burges C.J.C., Kaufman L. et al.. Support Vector Regression Machines. *Advances in Neural Information Processing Systems* 9, 1996. <https://papers.nips.cc/paper/1996/hash/d38901788c533e8286cb6400b40b386d-Abstract.html>. Дата обращения: 24.09.2026.

13 Friedman J.H.. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics* 29(5), 1189–1232, 2001. DOI: 10.1214/aos/1013203451.

14 Gibson R.F.. *Principles of Composite Material Mechanics*. CRC Press, 2016. <https://www.routledge.com/Principles-of-Composite-Material-Mechanics-Fourth-Edition-4th-Edition/Gibson/p/book/9781498720694>. Дата обращения: 24.09.2026.

15 Hoerl A.E., Kennard R.W.. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics* 12(1), 55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

16 Jones F.R.. *Composites Science, Technology, and Engineering*. Cambridge University Press, 2022. DOI: 10.1017/9781139565943.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК (продолжение)

17 Kohavi R.. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. Proceedings of IJCAI 1995, 1137–1143, 1995. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>. Дата обращения: 24.09.2026.

18 Lundberg S.M., Lee S.I.. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems 30, 2017. <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>. Дата обращения: 24.09.2026.

19 Pedregosa F., Varoquaux G., Gramfort A. et al.. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research 12, 2825–2830, 2011. <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Дата обращения: 24.09.2026.

20 Pineau J., Lamarre P.V., Sinha K. et al.. Improving Reproducibility in Machine Learning Research: A Report from the NeurIPS 2019 Reproducibility Program. Journal of Machine Learning Research 22(164), 1–20, 2021. <https://jmlr.org/papers/v22/20-303.html>. Дата обращения: 24.09.2026.

21 Pinnell M., Fields R., Zabora R.. Results of an Interlaboratory Study of the ASTM Standard Test Method for Tensile Properties of Polymer Matrix Composites D 3039. Journal of Testing and Evaluation 33(1), 2005. DOI: 10.1520/JTE12521.

22 Rumelhart D.E., Hinton G.E., Williams R.J.. Learning Representations by Back-propagating Errors. Nature 323, 533–536, 1986. DOI: 10.1038/323533a0.

23 Srivastava N., Hinton G., Krizhevsky A. et al.. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research 15, 1929–1958, 2014. <https://www.jmlr.org/papers/v15/srivastava14a.html>. Дата обращения: 24.09.2026.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК (продолжение)

24 Varma S., Simon R.. Bias in Error Estimation When Using Cross-Validation for Model Selection. BMC Bioinformatics 7, 91, 2006. DOI: 10.1186/1471-2105-7-91.

25 scikit-learn developers. Common Pitfalls and Recommended Practices. scikit-learn documentation, 2026. https://scikit-learn.org/stable/common_pitfalls.html.
Дата обращения: 24.09.2026.

26 scikit-learn developers. GridSearchCV API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html.
Дата обращения: 24.09.2026.

27 scikit-learn developers. mean_absolute_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html.
Дата обращения: 24.09.2026.

28 scikit-learn developers. Permutation Feature Importance. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/permutation_importance.html.
Дата обращения: 24.09.2026.

29 scikit-learn developers. r2_score API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html.
Дата обращения: 24.09.2026.

30 scikit-learn developers. root_mean_squared_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.root_mean_squared_error.html.
Дата обращения: 24.09.2026.