

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
« Наука о данных: профессиональный уровень (Data Science PRO)»

Слушатель

Фролов П.В.

Москва, 2026

СОДЕРЖАНИЕ

Введение.....	3
1 Аналитическая часть.....	4
1.1 Постановка задачи.....	4
1.2 Описание используемых методов.....	5
1.3 Разведочный анализ данных	9
2 Практическая часть	11
2.1 Предобработка данных	11
2.2 Разработка и обучение модели.....	17
2.3 Тестирование модели	19
2.4 Нейронная сеть для соотношения матрица–наполнитель.....	24
2.5 Разработка приложения	25
2.6 Создание удалённого репозитория и загрузка результатов работы на него	25
Заключение.....	26
Библиографический список	27

ВВЕДЕНИЕ

Композиционный материал состоит как минимум из двух компонентов. Матрица – связующее, которое удерживает компоненты вместе и передаёт нагрузку. Наполнитель – второй компонент, например волокна, которые усиливают материал. Этот пример поясняет общий принцип и не означает, что состав конкретных строк предоставленных таблиц известен: паспорт материалов отсутствует.

В работе рассматриваются две механические характеристики при растяжении. В упругой области материал восстанавливает форму после снятия нагрузки. Модуль упругости показывает жёсткость в этой области: чем он выше, тем меньше удлинение при одинаковом напряжении. Напряжение здесь означает нагрузку, делённую на площадь поперечного сечения образца. Прочность при растяжении показывает предельное напряжение перед разрушением. Предварительный прогноз этих величин в перспективе может помочь отбирать варианты для испытаний, но не заменяет само испытание.

Объект исследования – примеры композиционных материалов из двух предоставленных таблиц. Предмет – способы построения и проверки моделей. Цель работы – выяснить, позволяют ли имеющиеся столбцы оценивать модуль и прочность, а также восстановить записанное соотношение матрицы и наполнителя по 12 остальным полям, включая известные модуль и прочность. Для этого данные проверяются, объединяются и используются для сравнения нескольких методов. Полученная точность невысока, поэтому выводы относятся только к этой таблице.

1 АНАЛИТИЧЕСКАЯ ЧАСТЬ

1.1 Постановка задачи

Каждая строка таблиц рассматривается как один предоставленный пример материала, а столбец – как его характеристика. Файлы соединены по совпадающему индексу после проверки однозначности. Получены 1023 примера и 13 полей; ещё 17 строк были только в X_nip.xlsx и не имели пары. Индекс служит ключом, но не описывает материал и не подаётся модели. Пропуски и нечисловые значения отсутствуют.

Решаются три задачи прогноза числовой величины. В первых двух модель получает 11 характеристик, в том числе плотность, количество отвердителя, содержание эпоксидных групп, расход смолы и параметры нашивки. По ним отдельно оцениваются модуль и прочность; другая конечная характеристика не используется как подсказка. В третьей задаче сеть получает 12 остальных полей, включая известные модуль и прочность, и восстанавливает записанное отношение матрицы и наполнителя. Это не поиск оптимального состава.

Не указаны единицы шага и плотности нашивки, смысл суффикса _2, происхождение примеров, серии испытаний и типы компонентов. Эти сведения нельзя восстановить по одним числам, поэтому они зафиксированы как ограничения.

Три задачи и доступные им входы сопоставлены в таблице 1. Далее описаны использованные методы.

Таблица 1 – Постановки регрессии

Цель	Входы	Назначение
1	2	3
Модуль при растяжении, ГПа	11	Прямой прогноз
Прочность при растяжении, МПа	11	Прямой прогноз
Соотношение матрица– наполнитель	12	Оценка записанного отношения по 12 остальным полям

1.2 Описание используемых методов

Свойства композита зависят от компонентов, их долей, ориентации и изготовления. Матрица связывает материал и передаёт нагрузку, а армирование может повышать жёсткость и прочность в определённом направлении. Поэтому отклик зависит от направления испытания относительно армирования [14], [16]. Формование влияет на пропитку, отверждение, пористость и качество материала [8]. Набор содержит некоторые характеристики состава и изготовления, но форма их связи с результатом заранее неизвестна.

Правило смесей можно применять только при известных определениях долей и направления нагрузки. ASTM D3171 различает массовое и объёмное содержание и учитывает пустоты [4]. В таблицах смысл отношения матрицы и наполнителя не указан, поэтому его нельзя переводить в массовую или объёмную долю. Столбец «Температура вспышки, C_2» также нельзя называть температурой отверждения.

Модуль описывает жёсткость при упругом растяжении, прочность – предел перед разрушением. ASTM D3039/D3039M, ISO 527-4 и ISO 527-5 показывают влияние укладки, подготовки образца, среды, захватов и скорости испытания [1], [2], [3]. Согласованный протокол важен для сравнения лабораторий [21]. Влажность и температура также могут менять свойства [5], [7]. Эти условия для представленных примеров неизвестны.

1.2.1 Константная и гребневая модели

Регрессионная модель учится на примерах с известными входами и числовым ответом, а затем оценивает ответ для нового набора входов. Индекс строки исключён, поскольку это номер, а не характеристика. Для прогноза модуля или прочности другая конечная характеристика также исключена: она может быть неизвестна. Методы реализованы средствами scikit-learn [19].

Самый простой ориентир – константная модель: для любого входа она возвращает среднее значение цели в обучающих данных. Более сложный метод полезен только тогда, когда уменьшает ошибку относительно этого ориентира.

Гребневая регрессия (Ridge) складывает вклад каждого признака с подобранным коэффициентом. L2-штраф сдерживает чрезмерно большие коэффициенты [15]. Метод быстр, но без специально созданных признаков не описывает сложные нелинейные связи.

Перед гребневой регрессией входные столбцы стандартизуют: из значений вычитают среднее и делят на стандартное отклонение. Благодаря этому столбец с крупными числами не получает преимущество только из-за единиц измерения. Среднее и стандартное отклонение каждый раз вычисляются только по строкам, на которых модель обучается. Константная модель не использует входные признаки и остаётся единым базовым уровнем качества.

1.2.2 Ансамбли деревьев

Случайный лес (Random Forest) строит много деревьев решений и усредняет их ответы [6]. Деревья делят примеры по значениям признаков, поэтому лес находит нелинейные зависимости и взаимодействия. Усреднение повышает устойчивость, но модель занимает больше места, слабо работает за пределами известных диапазонов и труднее объясняется. Глубина деревьев подбирается только по обучающим данным.

Градиентный бустинг (Gradient Boosting) добавляет деревья последовательно: каждое исправляет ошибки уже построенной модели [13]. Он описывает нелинейности, но зависит от глубины, шага обучения и числа деревьев. Слишком сложная последовательность запоминает обучающие примеры, поэтому лес и бустинг сравниваются на одинаковых проверочных частях.

Достоинства и ограничения ансамблевых методов сопоставлены в таблице 2.

Таблица 2 – Сопоставление ансамблевых методов

Метод	Достоинства	Ограничения
1	2	3
Случайный лес	Нелинейности, взаимодействия, устойчивое усреднение	Размер модели, слабая экстраполяция
Градиентный бустинг	Последовательная коррекция ошибок	Чувствительность к глубине, темпу и числу итераций

1.2.3 Метод опорных векторов и многослойный персептрон

Регрессия на опорных векторах (SVR) строит зависимость с допустимой зоной ошибки ϵ ; более крупные отклонения штрафуются [11], [12]. Ядро позволяет описывать нелинейную связь. Метод подходит для умеренной выборки, но чувствителен к масштабу и параметрам C , ϵ и γ . Поэтому признаки и цель стандартизуют только по обучающим строкам каждой проверочной части.

Многослойный персептрон (MLP) преобразует входные числа в нескольких слоях. Связи имеют настраиваемые веса, которые меняются для уменьшения ошибки с помощью обратного распространения [22]. Сеть может описывать сложную зависимость, но на небольшой таблице легко переобучается. В использованной реализации сложность ограничивают компактная архитектура, L2-штраф и ранняя остановка; другой известный способ регуляризации – исключение части нейронов при обучении [23].

Лучший метод определяется по ошибке, а не выбирается заранее. Нейросеть по 12 известным полям, включая модуль и прочность, оценивает записанное отношение матрицы и наполнителя. Она не указывает, какие параметры надо изменить для получения желаемого материала, и не является оптимизацией рецептуры.

1.2.4 Оценка качества и предотвращение утечки данных

Из 1023 примеров заранее выделены обучающая выборка из 716 строк для разработки и тестовая выборка из 307 строк для итоговой проверки. Внутри

обучающей выборки выполнен поиск гиперпараметров по сетке с десятикратной перекрёстной проверкой: девять частей служат для обучения, десятая – для проверки, затем их роли меняются. Настройка выбирается по средней ошибке на десяти частях [17]. GridSearchCV перебирает заранее заданные варианты [26], а преобразования обучаются заново внутри каждого повтора [25]. Это защищает тестовую выборку от влияния на выбор, но не заменяет проверку на новых материалах [24], [9].

Используются три метрики. Средняя абсолютная ошибка (MAE) – средний модуль отклонения прогноза [27]. Корень из средней квадратичной ошибки (RMSE) измеряется в тех же единицах, но сильнее реагирует на крупные промахи [30]. Коэффициент R^2 сравнивает модель с прогнозом среднего: около нуля означает почти отсутствие улучшения, отрицательное значение – результат хуже среднего [29], [10]. R^2 не является процентом точности. Пермутационная важность показывает реакцию ошибки на перемешивание столбца, но не причинность [28].

$$RMSE = \sqrt{[(1/n)\sum_{i=1}^n (y_i - \hat{y}_i)^2]} \quad (1)$$

где n – число наблюдений оцениваемой выборки;

y_i – фактическое значение целевой переменной;

$\hat{y}_i$ – прогноз модели.

$$MAE = (1/n)\sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

где n – число наблюдений оцениваемой выборки;

y_i – фактическое значение целевой переменной;

$\hat{y}_i$ – прогноз модели.

$$R^2 = 1 - \sum_{i=1}^n (y_i - \hat{y}_i)^2 / \sum_{i=1}^n (y_i - \bar{y})^2 \quad (3)$$

где n – число наблюдений оцениваемой выборки;

y_i – фактическое значение целевой переменной;

$\hat{y}_i$ – прогноз модели;

$\bar{y}$ – среднее фактических значений оцениваемой выборки.

Константа вычисляется по обучающей части. Среднее отложенных строк отличается, поэтому её R^2 может быть не равно нулевым и даже отрицательным.

Используемые метрики и смысл каждой из них приведены в таблице 3.

Таблица 3 – Метрики регрессии

Метрика	Интерпретация
1	2
RMSE	Ошибка в единицах цели с повышенным весом крупных промахов
MAE	Среднее абсолютное отклонение в единицах цели
R^2	Сравнение с прогнозом среднего; на отложенной выборке может быть отрицательным

1.3 Разведочный анализ данных

Разведочный анализ – первичное изучение данных до обучения. Он выполнен только на 716 обучающих строках. Для 13 полей рассчитаны средние и медианы – значения в середине упорядоченного ряда. Построены распределения, диаграммы размаха и 78 попарных диаграмм; вычислены корреляции Пирсона и Спирмена. Пропусков нет. Угол нашивки принимает только 0° и 90° : 356 и 360 примеров. Квартиль $Q1$ отделяет нижнюю четверть значений, $Q3$ – верхнюю; между ними находится средняя половина ряда. Межквартильный размах (IQR) равен расстоянию между $Q1$ и $Q3$. Правило IQR отмечает необычные значения, но не доказывает ошибку.

Наибольшая абсолютная корреляция Пирсона равна 0,119 между углом и плотностью нашивки. Это слабая парная связь, но несколько признаков вместе могут содержать нелинейную информацию. Поэтому вывод делается по ошибкам моделей.

На рисунке 1 гистограммы показывают частоту значений, диаграммы размаха – центр, разброс и удалённые точки, а диаграммы рассеяния – пары характеристик отдельных строк. Полный комплект графиков сохранён в репозитории.




Рисунок 1 – Репрезентативные графики распределения, размаха и рассеяния

2 ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1 Предобработка данных

После проверки листов, столбцов, типов и уникальности индекса файлы соединены по совпадающему индексу. Затем 1023 строки разделены при состоянии генератора 42: 716 использованы для разработки, 307 – для итоговой оценки. Индекс исключён из входов. Результаты проверки приведены в таблице 4.

Таблица 4 – Аудит и разбиение данных

Строк	Полей	Обучение	Отложенная оценка	Пропуски	Состояние генератора
1	2	3	4	5	6
1023	13	716	307	0	42

2.1.1 Статистики, выбросы и корреляции

Для каждого столбца вычислены описательные показатели. Необычными считались значения ниже $Q1 - 1,5 IQR$ или выше $Q3 + 1,5 IQR$. Больше всего кандидатов найдено в плотности нашивки – 16, количестве отвердителя – 9 и температуре вспышки – 8. Они проверяются как вариант обработки, а не объявляются ошибками.

У количества отвердителя 468 из 716 значений с обозначением «м. %» превышают 100. Основа процентов не объяснена, поэтому числа сохранены без пересчёта. Наибольшая корреляция 0,119 получена между углом и плотностью нашивки. Оба результата относятся только к обучающей части.

2.1.2 Распределения до и после нормализации

Для рисунков столбцы с разными единицами линейно переведены в диапазон от 0 до 1 с помощью MinMaxScaler. Модели эти иллюстрационные данные не используют. При обучении Ridge стандартизуют входы X, а для SVR и MLP – входы X и цель y. Параметры вычисляются заново внутри обучающей части; деревья используют исходный масштаб.

На рисунке 2 сопоставлены отношение компонентов, плотность и модуль упругости. После линейного преобразования в диапазон $[0; 1]$ сохраняются форма распределения, асимметрия и взаимный порядок наблюдений; различие физических единиц устраняется только для сопоставления графиков.

Распределения train до и после нормализации, $n=716$




Рисунок 2 – Распределения до и после нормализации: Соотношение матрица-наполнитель; Плотность, кг/м3; модуль упругости, ГПа

На рисунке 3 представлены количество отвердителя, содержание эпоксидных групп и температура вспышки. Масштабирование не устраняет длинные хвосты и не меняет неопределённую семантику исходных единиц; значения не получают новой физической трактовки.

Распределения train до и после нормализации, n=716




Рисунок 3 – Распределения до и после нормализации: Количество отвердителя, м.%; Содержание эпоксидных групп,%_2; Температура вспышки, С_2

На рисунке 4 показаны поверхностная плотность и две целевые механические характеристики. Их диапазоны различаются, а преобразование лишь переводит каждую переменную в общую числовую шкалу; цели не смешиваются и оцениваются отдельно.

Распределения train до и после нормализации, n=716




Рисунок 4 – Распределения до и после нормализации: Поверхностная плотность, г/м²; Модуль упругости при растяжении, ГПа; Прочность при растяжении, МПа

На рисунке 5 сопоставлены потребление смолы и бинарный угол нашивки. Угол сохраняет два уровня, соответствующие 0° и 90°; непрерывная интерпретация промежуточных углов из этих данных невозможна.

Распределения train до и после нормализации, n=716




Рисунок 5 – Распределения до и после нормализации: Потребление смолы, г/м2;
Угол нашивки, град

На рисунке 6 показаны шаг и плотность нашивки. Неизвестные единицы ограничивают физическое толкование, однако линейное масштабирование сохраняет наблюдавшиеся относительные различия. Эти иллюстрационные преобразования не используются при обучении моделей.

Распределения train до и после нормализации, n=716




Рисунок 6 – Распределения до и после нормализации: Шаг нашивки; Плотность нашивки

2.1.3 Решения по предобработке

Пропусков нет, поэтому заполнение не требуется. Для Ridge, SVR и MLP стандартизация включена в один конвейер с моделью и не использует проверочные строки. Деревьям изменение масштаба не нужно.

Необычные значения проверены двумя способами: модели обучались на всех строках и после IQR-фильтрации. Для обеих прямых задач фильтр по 11 входам убирал 53 строки и оставлял 663 из 716. Для задачи отношения фильтр по 12 входам убирал 61 строку и оставлял 655; средняя RMSE нейросети менялась с 0,935319 до 0,937889, то есть не улучшалась. Границы фильтра каждый раз рассчитывались только на обучающей части, входы X и ответы y удалялись вместе, а проверочные и отложенные строки сохранялись. Поэтому для итоговых моделей выбран вариант без удаления.

Сведений о партиях и повторных сериях нет. Поэтому нельзя проверить, не оказались ли близкие примеры по разные стороны случайного разделения.

2.2 Разработка и обучение модели

Для модуля и прочности сравниваются прогноз среднего, Ridge, случайный лес, градиентный бустинг и SVR; для отношения – прогноз среднего и MLP. Гиперпараметры выбираются по средней RMSE десятикратной перекрёстной проверки на 716 строках, дополнительно записываются MAE и R^2 . После выбора модель заново обучается на всех 716 строках и один раз применяется к тестовой выборке из 307 строк.

Для модуля выбран прогноз среднего: более сложные методы не снизили RMSE. Для прочности минимальную среднюю RMSE получил бустинг, но преимущество мало: он лучше константы в 4 из 10 частей, а константа – в 6. Средняя парная разность, вычисленная как RMSE константы минус RMSE бустинга, равна +0,291 МПа при стандартном отклонении 8,345 МПа. Это не доказывает значимого превосходства.

Рисунок 7 показывает порядок проверки: 307 строк составляют тестовую выборку, а внутри остальных 716 каждая настройка десять раз обучается на девяти частях и проверяется на десятой. После выбора модель заново обучается на всех 716 строках.



В каждом цикле предобработка и модель обучаются заново. Тестовая выборка не участвует в выборе.

Критерий выбора: средняя RMSE – ошибка в единицах свойства, которая сильнее учитывает крупные промахи.

Рисунок 7 – Отделение итоговой выборки и обучение обработки внутри перекрёстной проверки

Для повторяемости диапазоны настроек зафиксированы: Ridge $\alpha \in \{0,01; 0,1; 1; 10; 100\}$; Random Forest – $(n_estimators, max_depth, min_samples_leaf) \in \{(200, None, 1), (150, None, 3), (200, 10, 1), (150, 10, 3)\}$;

Gradient Boosting – $\text{learning_rate} \in \{0,03; 0,1\}$, $\text{max_depth} \in \{2; 3\}$, $\text{n_estimators}=150$; SVR – $C \in \{0,3; 1; 3\}$, $\text{epsilon} \in \{0,05; 0,1\}$, $\text{gamma}=\text{scale}$. Проверены варианты со всеми строками и с IQR-фильтрацией.

Зафиксированные до оценки на отложенной выборке конфигурации перечислены в таблице 5.

Таблица 5 – Зафиксированные конфигурации

Цель	Модель	Вариант	Параметры
1	2	3	4
Модуль при растяжении	Константная модель (DummyRegressor, среднее)	Без удаления	без гиперпараметров
Прочность при растяжении	Градиентный бустинг	Без удаления	$\text{learning_rate}=0,03$; $\text{max_depth}=2$; $\text{n_estimators}=150$
Соотношение матрица–наполнитель	Многослойный персептрон (MLPRegressor)	Без удаления	$\text{hidden}=(32,16)$; $\text{alpha}=0,01$

2.2.1 Результаты перекрёстной проверки

Таблица 6 показывает результаты до обращения к 307 отложенным строкам. Для модуля выбрана константа. Для прочности бустинг лишь немного опередил её по средней RMSE, хотя проиграл в 6 из 10 частей. Для отношения MLP получила RMSE 0,935 против 0,906 у константы и уже здесь оказалась хуже. Стандартное отклонение показывает разброс между частями, а не значимость различия.

Таблица 6 – Ключевые результаты десятикратной перекрёстной проверки

Задача	Модель	RMSE, среднее ± СКО	MAE, среднее	R ² , среднее
1	2	3	4	5
Модуль, ГПа	Константная модель	3,087 ± 0,257	2,483	-0,015
Прочность, МПа	Константная модель	490,500 ± 24,618	384,750	-0,011
Прочность, МПа	Градиентный бустинг	490,209 ± 23,852	387,225	-0,010
Отношение (база не ука- зана)	Константная модель	0,906 ± 0,047	0,719	-0,008
Отношение (база не ука- зана)	Многослойный персептрон	0,935 ± 0,058	0,751	-0,072

2.3 Тестирование модели

Таблица 7 содержит окончательные ошибки. Звёздочка отмечает модели, выбранные заранее. RMSE и MAE выражены в единицах цели, R² безразмерен. Модуль и прочность нельзя сравнивать напрямую: их единицы различаются.

Таблица 7 – Ошибки моделей для двух прямых задач

Цель	Модель	RMSE, обучение	RMSE, отложенная	MAE, отложенная	R ² , отложенная
1	2	3	4	5	6
Модуль, ГПа	Константная модель*	3,095	3,178	2,556	-0,016
Модуль, ГПа	Гребневая регрессия	3,066	3,190	2,567	-0,024
Модуль, ГПа	Градиентный бустинг	2,867	3,221	2,587	-0,044
Модуль, ГПа	Случайный лес	1,817	3,311	2,643	-0,104
Модуль, ГПа	Метод опорных векторов	2,813	3,263	2,623	-0,072
Прочность, МПа	Константная модель	490,497	473,288	378,984	-0,0003
Прочность, МПа	Гребневая регрессия	485,154	471,726	378,437	0,006
Прочность, МПа	Градиентный бустинг*	447,149	471,410	380,152	0,008
Прочность, МПа	Случайный лес	298,601	476,225	381,814	-0,013
Прочность, МПа	Метод опорных векторов	446,934	484,995	390,329	-0,050

Для модуля остался прогноз среднего: RMSE 3,178 ГПа, MAE 2,556 ГПа, R² –0,016. Для прочности бустинг дал RMSE 471,410 МПа вместо 473,288 МПа у константы, но MAE 380,152 МПа оказалась хуже 378,984 МПа. R² бустинга 0,008 означает почти отсутствующее улучшение. Случайный лес показал переобучение: его ошибка на обучении намного ниже итоговой.

2.3.1 Фактические и прогнозные значения

На рисунке 8 по горизонтали отложены известные значения, по вертикали – прогнозы. Хорошая модель дала бы точки около диагонали. Для модуля

константа образует горизонтальную линию; для прочности точки сильно рассеяны. Значит, испытанные модели слабо объясняют различия между примерами.




Рисунок 8 – Фактические и прогнозные значения модуля и прочности

2.3.2 Анализ остатков

Остаток – известное значение минус прогноз. На рисунке 9 по горизонтали показан прогноз, по вертикали – остаток. У хорошей модели точки образовали бы узкую полосу около нуля. Здесь разброс широк и на обучающих, и на отложенных строках. Это подтверждает ограниченную точность, но не отсутствие физической зависимости.




Рисунок 9 – Остатки моделей модуля и прочности на обучающей и отложенной выборках

2.3.3 Пермутационная важность и ограничения

Пермутационная важность показывает изменение RMSE после случайного перемешивания одного столбца. На рисунке 10 столбцы вправо от нуля показывают рост RMSE, влево – снижение; чёрные отрезки показывают разброс десяти повторов, а не физическую неопределённость. У константной модели модуля важности равны нулю, потому что она не использует входы. Это не означает, что признаки физически неважны.

SHAP – другой способ объяснения отдельных прогнозов через сумму вкладов признаков [18]. В работе рассчитана пермутационная важность, поэтому результаты этих методов не смешиваются.




Рисунок 10 – Пермутационная важность модели прочности

Итоговые строки взяты из той же таблицы. Поскольку происхождение, партии и повторные серии неизвестны, результат характеризует только это разделение. Для оценки переноса нужны новые материалы или независимые группы опытов.

2.4 Нейронная сеть для соотношения матрица–наполнитель

Нейросеть оценивает записанное соотношение матрицы и наполнителя. Структура 12–32–16–1 означает 12 входов, скрытые слои из 32 и 16 нейронов и один числовой выход. ReLU выполняет нелинейное преобразование, Adam обновляет веса, а L2-штраф $\alpha=0,01$ ограничивает их величину; всего 961 настраиваемый параметр. По перекрёстной проверке RMSE сети $0,935 \pm 0,058$ против $0,906 \pm 0,047$ у константы.

Эпоха – один полный проход по обучающим примерам. Ранняя остановка прекращает обучение, когда внутренняя ошибка не улучшается. Обучение завершилось после 76 эпох с восстановлением весов эпохи 35: 644 строки обновляли веса, 72 контролировали остановку. Масштабирование X и y вычислено до этого внутреннего разделения, поэтому кривая не полностью независима; внешняя перекрёстная проверка и тестовая выборка из 307 строк изолированы. Состояния 42–44 меняли веса, разделение и мини-пакеты.

Сеть получает 12 остальных полей, включая известные модуль и прочность, и восстанавливает записанное отношение. На отложенных строках она хуже прогноза среднего: RMSE 0,944 против 0,926, $R^2 -0,040$. Результат нельзя использовать как рекомендацию соотношения компонентов или подбор рецептуры.

Таблица 8 сопоставляет нейросеть с прогнозом среднего. На рисунке 11 слева показаны функция потерь на обучающих строках и R^2 на внутренней проверке: меньшее значение потерь и большее R^2 соответствуют улучшению. Справа показан разброс RMSE перекрёстной проверки при трёх состояниях генератора.

Таблица 8 – Ошибки константной и нейросетевой моделей

Модель	RMSE, обучение	RMSE, отложенная	MAE, отложенная	R^2 , отложенная
1	2	3	4	5
Константная модель	0,907	0,926	0,752	-0,001
Многослойный персептрон*	0,870	0,944	0,777	-0,040




Рисунок 11 – Диагностика обучения MLP и вариативность перекрёстной проверки при трёх состояниях генератора

2.5 Разработка приложения

Приложение демонстрирует две прямые модели. Пользователь вводит 11 характеристик, программа проверяет значения и выдаёт модуль и прочность. Нейросеть отношения в интерфейс не включена. Для медианных входов получены 73,2073 ГПа и 2502,06 МПа; это пример работы интерфейса, а не испытанный материал.

Приложение запускается в Docker по командам README. Кнопка «Прогноз» передаёт 11 значений двум сохранённым моделям. При выходе за диапазон обучающей таблицы появляется предупреждение: в этой области модель не проверялась.

2.6 Создание удалённого репозитория и загрузка результатов работы на него

Профиль: <https://github.com/fpvcstep>; репозиторий: <https://github.com/fpvcstep/composites-property-prediction>; история коммитов: <https://github.com/fpvcstep/composites-property-prediction/commits/main> [20]. Команды и ограничения воспроизводимости приведены в README.

ЗАКЛЮЧЕНИЕ

В работе проверено, позволяют ли характеристики из двух таблиц оценивать модуль и прочность при растяжении. После соединения получены 1023 примера; 716 использованы для разработки, 307 – для итоговой проверки. Пропусков и полных дубликатов нет. Наибольшая абсолютная корреляция 0,119 показывает слабую линейную связь отдельных столбцов.

Удаление кандидатов по правилу IQR не улучшило выбранные модели: для прямых задач оставалось 663 строки, для отношения – 655. Поэтому итоговые модели обучены на всех 716 строках. Для модуля ни один испытанный метод не превзошёл прогноз среднего; RMSE 3,178 ГПа, MAE 2,556 ГПа, R^2 –0,016.

Для прочности выбран бустинг, но его преимущество мало: он лучше константы в 4 из 10 частей; средняя парная разность RMSE +0,291 МПа при отклонении 8,345 МПа. На отложенной части RMSE 471,410 МПа, MAE 380,152 МПа, R^2 0,008. Практическая точность не подтверждена.

Сеть 12–32–16–1 по 12 полям, включая известные модуль и прочность, оценивает записанное отношение. Она уступила прогнозу среднего: RMSE 0,944, R^2 –0,040. Поэтому сеть не даёт надёжной рекомендации состава. Приложение показывает только два прямых прогноза и предупреждает о выходе за известные диапазоны.

Результат показывает ограниченное качество испытанных моделей на этой таблице, а не отсутствие физических закономерностей. Для улучшения нужны паспорт данных, сведения о партиях и условиях испытаний, новые независимые примеры и лабораторная проверка. До этого прогнозы не заменяют испытание.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1 ASTM International. ASTM D3039/D3039M-17(2025): Standard Test Method for Tensile Properties of Polymer Matrix Composite Materials. 2025. DOI: 10.1520/D3039_D3039M-17R25.

2 International Organization for Standardization. ISO 527-4:2023 Plastics – Determination of tensile properties – Part 4: Test conditions for isotropic and orthotropic fibre-reinforced plastic composites. ISO, 2023. <https://www.iso.org/standard/85809.html>. Дата обращения: 24.09.2026.

3 International Organization for Standardization. ISO 527-5:2021 Plastics – Determination of tensile properties – Part 5: Test conditions for unidirectional fibre-reinforced plastic composites. ISO, 2021. <https://www.iso.org/standard/80370.html>. Дата обращения: 24.09.2026.

4 ASTM International. ASTM D3171-22: Standard Test Methods for Constituent Content of Composite Materials. 2022. DOI: 10.1520/D3171-22.

5 ASTM International. ASTM D5229/D5229M-20: Standard Test Method for Moisture Absorption Properties and Equilibrium Conditioning of Polymer Matrix Composite Materials. 2020. DOI: 10.1520/D5229_D5229M-20.

6 Breiman L. Random Forests. Machine Learning 45, 5–32, 2001. DOI: 10.1023/A:1010933404324.

7 Browning C.E., Husman G.E., Whitney J.M. Moisture Effects in Epoxy Matrix Composites. Composite Materials: Testing and Design (Fourth Conference), ASTM STP 617, 1977, pp. 481–496. DOI: 10.1520/STP26961S.

8 Campbell F.C. Manufacturing Processes for Advanced Composites. Elsevier Science, 2003. DOI: 10.1016/B978-1-85617-415-2.X5000-X.

9 Cawley G.C., Talbot N.L.C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research 11, 2079–2107, 2010. <https://www.jmlr.org/papers/v11/cawley10a.html>. Дата обращения: 24.09.2026.

10 Chicco D., Warrens M.J., Jurman G. The Coefficient of Determination R-squared Is More Informative than SMAPE, MAE, MAPE, MSE and RMSE in Regression Analysis Evaluation. *PeerJ Computer Science* 7:e623, 2021. DOI: 10.7717/peerj-cs.623.

11 Cortes C., Vapnik V. Support-Vector Networks. *Machine Learning* 20, 273–297, 1995. DOI: 10.1007/BF00994018.

12 Drucker H., Burges C.J.C., Kaufman L. et al. Support Vector Regression Machines. *Advances in Neural Information Processing Systems* 9, 1996. <https://papers.nips.cc/paper/1996/hash/d38901788c533e8286cb6400b40b386d-Abstract.html>.
Дата обращения: 24.09.2026.

13 Friedman J.H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics* 29(5), 1189–1232, 2001. DOI: 10.1214/aos/1013203451.

14 Gibson R.F. *Principles of Composite Material Mechanics*. CRC Press, 2016. <https://www.routledge.com/Principles-of-Composite-Material-Mechanics-Fourth-Edition-4th-Edition/Gibson/p/book/9781498720694>. Дата обращения: 24.09.2026.

15 Hoerl A.E., Kennard R.W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics* 12(1), 55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

16 Jones F.R. *Composites Science, Technology, and Engineering*. Cambridge University Press, 2022. DOI: 10.1017/9781139565943.

17 Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. *Proceedings of IJCAI 1995*, 1137–1143. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>. Дата обращения: 24.09.2026.

18 Lundberg S.M., Lee S. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems* 30, 2017. <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>.
Дата обращения: 24.09.2026.

19 Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12, 2825–2830, 2011. <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Дата обращения: 24.09.2026.

20 Pineau J., Vincent-Lamarre P., Sinha K. et al. Improving Reproducibility in Machine Learning Research: A Report from the NeurIPS 2019 Reproducibility Program. *Journal of Machine Learning Research* 22(164), 1–20, 2021. <https://jmlr.org/papers/v22/20-303.html>. Дата обращения: 24.09.2026.

21 Pinnell M., Fields R., Zabora R. Results of an Interlaboratory Study of the ASTM Standard Test Method for Tensile Properties of Polymer Matrix Composites D 3039. *Journal of Testing and Evaluation* 33(1), 2005. DOI: 10.1520/JTE12521.

22 Rumelhart D.E., Hinton G.E., Williams R.J. Learning Representations by Back-propagating Errors. *Nature* 323, 533–536, 1986. DOI: 10.1038/323533a0.

23 Srivastava N., Hinton G., Krizhevsky A. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research* 15, 1929–1958, 2014. <https://www.jmlr.org/papers/v15/srivastava14a.html>. Дата обращения: 24.09.2026.

24 Varma S., Simon R. Bias in Error Estimation When Using Cross-Validation for Model Selection. *BMC Bioinformatics* 7, 91, 2006. DOI: 10.1186/1471-2105-7-91.

25 scikit-learn developers. Common Pitfalls and Recommended Practices. scikit-learn documentation, 2026. https://scikit-learn.org/stable/common_pitfalls.html. Дата обращения: 24.09.2026.

26 scikit-learn developers. GridSearchCV API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. Дата обращения: 24.09.2026.

27 scikit-learn developers. mean_absolute_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html. Дата обращения: 24.09.2026.

28 scikit-learn developers. Permutation Feature Importance. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/permutation_importance.html. Дата обращения: 24.09.2026.

29 scikit-learn developers. `r2_score` API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html. Дата обращения: 24.09.2026.

30 scikit-learn developers. `root_mean_squared_error` API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.root_mean_squared_error.html. Дата обращения: 24.09.2026.