

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
« Наука о данных: профессиональный уровень (Data Science PRO)»

Слушатель

Фролов П.В.

Москва, 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 АНАЛИТИЧЕСКАЯ ЧАСТЬ	4
1.1 Постановка задачи	4
1.2 Описание используемых методов	5
1.2.1 Прогноз среднего и гребневая регрессия	6
1.2.2 Случайный лес и градиентный бустинг.....	7
1.2.3 Метод опорных векторов	7
1.2.4 Нейронная сеть для отдельной задачи.....	8
1.2.5 Как проверялись модели	8
1.3 Разведочный анализ данных	9
2 ПРАКТИЧЕСКАЯ ЧАСТЬ.....	12
2.1 Предобработка данных	12
2.1.1 Статистики, выбросы и корреляции	12
2.1.2 Распределения до и после нормализации.....	12
2.1.3 Решения по предобработке	17
2.2 Разработка и обучение модели	18
2.2.1 Результаты перекрёстной проверки	19
2.3 Тестирование модели.....	19
2.3.1 Фактические и прогнозные значения.....	20
2.3.2 Анализ остатков	21
2.3.3 Какие характеристики использует модель	22
2.4 Нейронная сеть для соотношения матрица–наполнитель	23
2.5 Разработка приложения	25
2.6 Создание удалённого репозитория.....	25
ЗАКЛЮЧЕНИЕ	26
БИБЛИОГРАФИЧЕСКИЙ СПИСОК	27

ВВЕДЕНИЕ

Композиционный материал состоит из нескольких компонентов. Связующее удерживает их вместе; в композитах его также называют матрицей. Наполнитель добавляют, чтобы получить нужные свойства. Он, например, может выполнять армирующую функцию, то есть усиливать материал. Итоговые свойства зависят от сочетания компонентов и способа изготовления, поэтому их нельзя надёжно определить только по свойствам отдельных частей.

В работе используются две таблицы Excel. В каждой строке записан один представленный материал. Для него указаны характеристики состава и изготовления: соотношение связующего и наполнителя, плотность, количество отвердителя, потребление смолы и параметры нашивки. В таблицах также есть известные значения двух конечных свойств. По таким примерам модели учатся связывать характеристики материала с его свойствами.

Нужно прогнозировать два свойства. Модуль упругости при растяжении характеризует жёсткость материала при обратимом растяжении, когда после снятия нагрузки восстанавливается исходная форма. Прочность при растяжении показывает предельное напряжение до разрушения. Напряжение здесь означает нагрузку, делённую на площадь поперечного сечения. Для решения задачи таблицы объединяют и проверяют, а затем данные разделяют на обучающую и тестовую выборки. На первой подбирают модели, а вторую используют только для итоговой проверки. Отдельно по заданию нейронная сеть оценивает соотношение матрицы и наполнителя.

1 АНАЛИТИЧЕСКАЯ ЧАСТЬ

1.1 Постановка задачи

Цель работы – по предоставленным таблицам построить модели для прогноза модуля упругости при растяжении и прочности при растяжении, проверить качество прогнозов и включить выбранные модели в демонстрационное приложение.

Файлы X_br.xlsx и X_nur.xlsx соединены по совпадающему индексу. Индекс нужен только для соединения и не передаётся моделям. Получены 1023 строки и 13 содержательных столбцов. Ещё 17 строк файла X_nur.xlsx не имели пары. Одна строка описывает один представленный материал: его характеристики и известные значения свойств.

2 из 13 столбцов – свойства, которые нужно прогнозировать: «Модуль упругости при растяжении, ГПа» и «Прочность при растяжении, МПа». В этой работе для каждого свойства строится отдельная модель. Оба конечных свойства исключаются из входных данных, поэтому остаётся $13 - 2 = 11$ входных характеристик.

Эти 11 характеристик: соотношение матрицы и наполнителя; плотность; «модуль упругости, ГПа»; количество отвердителя; содержание эпоксидных групп; температура вспышки; поверхностная плотность; потребление смолы; угол нашивки; шаг нашивки; плотность нашивки. Столбец «модуль упругости, ГПа» используется как входная характеристика. «Модуль упругости при растяжении, ГПа» – другое поле и одно из прогнозируемых свойств. Смысл первого столбца в исходных материалах подробно не раскрыт, поэтому эти два поля нельзя считать взаимозаменяемыми.

Для отдельной задачи нейронная сеть оценивает один столбец – «Соотношение матрица–наполнитель». Его исключают, а остальные 12 столбцов оставляют: $13 - 1 = 12$. В эти 12 характеристик входят оба конечных свойства. Поэтому сеть восстанавливает известный показатель по остальным данным, а не подбирает состав материала.

Таблица 1 – Три задачи и число входных характеристик

Свойство или показатель	Число входов	Назначение
Модуль упругости при растяжении, ГПа	11	Прямой прогноз
Прочность при растяжении, МПа	11	Прямой прогноз
Соотношение матрица–наполнитель	12	Отдельная задача нейронной сети

1.2 Описание используемых методов

Машинное обучение в этой работе означает поиск числового правила по примерам с известными ответами. Для модуля упругости и прочности используются 11 входных характеристик и сравниваются пять подходов: прогноз среднего, гребневая регрессия, случайный лес, градиентный бустинг и метод опорных векторов. Две выбранные модели затем включаются в приложение. Отдельная нейронная сеть оценивает соотношение матрицы и наполнителя по 12 характеристикам, включая два известных конечных свойства; эта задача не является подбором рецептуры.

Работа состоит из восьми шагов. 1) Проверить и объединить два файла Excel по индексу: результат содержит 1023 строки и 13 содержательных столбцов. 2) Сразу отделить 716 строк для разработки и 307 строк для итоговой проверки, чтобы отложенные ответы не влияли на выбор решения.

3) Изучить только 716 строк: проверить пропуски, распределения, необычные значения и простые связи. 4) Подготовить данные: кодировать два направления угла, а для чувствительных к масштабу методов рассчитывать преобразования только по обучающей части.

5) Обучить и сравнить модели на 716 строках в десятикратной перекрёстной проверке. 6) После выбора один раз проверить две прямые модели на 307 отложенных строках. Для отдельной нейросети сохраняются то же внешнее разделение и выбор до итоговой проверки; часть обучающих строк используется для ранней остановки.

7) Включить в приложение две прямые модели: пользователь вводит 11 характеристик и получает прогнозы модуля и прочности. 8) Сохранить код, данные, модели и документы в удалённом репозитории, чтобы состав работы и расчёты можно было проверить.

Свойства композита зависят от состава, расположения компонентов и способа изготовления [8], [14], [16]. Методы разной сложности позволяют проверить, насколько эти связи видны в предоставленных таблицах. В материалах не объяснено, является ли «Соотношение матрица–наполнитель» массовой или объёмной долей [4], а «Температура вспышки» не означает температуру отверждения.

На результат испытаний могут влиять подготовка материала, направление укладки, закрепление, скорость, влажность и температура [1], [2], [3], [5], [7], [21]. Для строк таблицы эти условия не указаны, поэтому выводы относятся к предоставленным данным и требуют внешней проверки.

1.2.1 Прогноз среднего и гребневая регрессия

Сначала задаётся простой ориентир – прогноз среднего. Такая модель не смотрит на характеристики материала и выдаёт всем строкам среднее значение свойства в данных для обучения. Более сложный метод имеет практический смысл только тогда, когда ошибается меньше этого ориентира.

Гребневая регрессия (Ridge) умножает каждую входную характеристику на свой коэффициент, складывает результаты и добавляет постоянную поправку. Коэффициенты подбираются по строкам с известными значениями свойства. Дополнительное ограничение не даёт им становиться чрезмерно большими [15]. Метод реализован средствами `scikit-learn` [19].

Ridge включена в сравнение как простая и понятная модель. Она показывает, достаточно ли суммы отдельных вкладов для прогноза. Перед обучением значения приводятся к сопоставимому масштабу, чтобы столбец с крупными числами не получил преимущество только из-за единиц измерения. Такое приведение каждый раз рассчитывается только по данным для обучения.

1.2.2 Случайный лес и градиентный бустинг

Случайный лес (Random Forest) строит много деревьев решений и усредняет их ответы [6]. Каждое дерево последовательно разделяет строки по значениям характеристик. Так модель может находить связи сложнее простой суммы. Усреднение уменьшает влияние отдельного дерева, но модель труднее объяснять и она плохо работает за пределами уже встречавшихся диапазонов.

Градиентный бустинг (Gradient Boosting) также использует деревья, но строит их по очереди. Каждое новое дерево старается исправить ошибки предыдущих [13]. Такой способ может находить сложные связи, однако слишком большая модель способна запомнить особенности данных для обучения. Поэтому глубину деревьев и скорость исправления ошибок подбирают на проверочных частях.

Главное различие методов показано в таблице 2. Лес усредняет много деревьев, а бустинг исправляет ошибки шаг за шагом.

Таблица 2 – Случайный лес и градиентный бустинг

Метод	Достоинства	Ограничения
Случайный лес	Находит сложные связи, усредняет ответы деревьев	Труднее объяснять; слабый прогноз вне известных диапазонов
Градиентный бустинг	Исправляет ошибки шаг за шагом	Нужен контроль сложности

1.2.3 Метод опорных векторов

Метод опорных векторов для числового прогноза обозначается SVR. Он получает строки с известными входными характеристиками и значением свойства и учится рассчитывать свойство для новой строки [11], [12]. Влияние одной характеристики может зависеть от сочетания остальных; SVR позволяет учитывать такие связи.

Малые отклонения в пределах допуска не увеличивают величину ошибки, по которой подбирается модель; при большем отклонении учитывается его часть

сверх допуска. Одновременно ограничивается сложность модели, чтобы она не повторяла случайные особенности таблицы. Опорные векторы – это входные характеристики части обучающих примеров, которые используются для прогноза.

SVR чувствителен к масштабу чисел. Входные характеристики и прогнозируемое свойство приводятся к сопоставимому масштабу внутри каждого блока перекрёстной проверки только по его обучающей части. После расчёта результат переводится обратно в ГПа или МПа. Настройки SVR выбираются без использования 307 строк итоговой проверки.

1.2.4 Нейронная сеть для отдельной задачи

Многослойный персептрон (MLP) – нейронная сеть для числового прогноза [22], [23]. В этой работе она решает отдельную задачу: получает 12 характеристик, включая известные модуль и прочность, и оценивает записанное в таблице соотношение матрицы и наполнителя. Сеть не является шестым методом двух прямых прогнозов и не входит в приложение.

MLP передаёт числа через последовательные слои и изменяет веса связей, уменьшая ошибку. Нелинейные преобразования позволяют учитывать совместное влияние характеристик, но небольшая таблица повышает риск подгонки. Поэтому используются компактная архитектура, ограничение весов, масштабирование и ранняя остановка; 307 строк итоговой проверки при этом остаются закрытыми.

1.2.5 Как проверялись модели

Из 1023 строк заранее выделены 716 строк для разработки и 307 строк для итоговой проверки. Последние не используются при выборе модели. Внутри 716 строк выполняется десятикратная перекрёстная проверка: данные делят на десять частей, модель учится на девяти и проверяется на десятой. Затем проверочная часть меняется, пока каждая не побывает в этой роли [17].

Для каждой модели заранее задаётся несколько вариантов настроек. Их перебор называют поиском по сетке [26]. Все преобразования чисел заново рассчитываются внутри каждой обучающей части [25]. Настройка выбирается по

средней ошибке десяти проверок. Такой порядок не позволяет тестовой выборке повлиять на выбор, но не заменяет проверку на новых материалах [24], [9].

Качество описывают тремя показателями. Средняя абсолютная ошибка (MAE) показывает обычный размер отклонения прогноза от известного значения [27]. Корень из средней квадратичной ошибки (RMSE) выражается в тех же единицах свойства, но сильнее учитывает крупные промахи [30]. Для обеих ошибок меньшее значение лучше.

Коэффициент R^2 сравнивает модель с прогнозом среднего [29], [10]. Значение около нуля означает, что улучшения почти нет. Отрицательное значение означает результат хуже среднего. R^2 не является процентом точности.

Среднее для простого ориентира вычисляется только по данным для обучения. Среднее тестовых строк может немного отличаться. Поэтому R^2 прогноза среднего на тестовой выборке не обязано быть равно нулевым.

Краткий смысл показателей приведён в таблице 3.

Таблица 3 – Метрики регрессии

Метрика	Интерпретация
RMSE	Ошибка в единицах свойства; крупные промахи влияют сильнее
MAE	Средний размер ошибки в единицах свойства
R^2	Сравнение с прогнозом среднего; это не процент точности

1.3 Разведочный анализ данных

Разведочный анализ данных – это знакомство с таблицей до обучения моделей. Он выполнен только на 716 обучающих строках. Для каждого из 13 столбцов рассчитаны среднее и медиана. Медиана – значение в середине упорядоченного ряда. Результаты приведены в таблице 4. Также построены распределения, диаграммы размаха и 78 графиков для пар столбцов. Пропусков не найдено. Угол нашивки принимает только два значения: 0° у 356 строк и 90° у 360 строк.


Для поиска необычных чисел использован межквартильный размах (IQR). Q1 и Q3 ограничивают среднюю половину упорядоченных значений, а IQR равен расстоянию между ними. Значения далеко за этими границами отмечаются для проверки, но не объявляются ошибками автоматически. Самая большая по модулю парная корреляция равна 0,119 между углом и плотностью нашивки. Это слабая связь. Однако несколько характеристик вместе могут быть полезнее, поэтому окончательный вывод делают по ошибкам моделей.

Рисунок 1 помогает увидеть данные тремя способами. Гистограммы показывают, какие значения встречаются чаще. Диаграммы размаха показывают середину, общий разброс и удалённые точки. На диаграммах рассеяния каждая точка – одна строка таблицы, а её положение задают две выбранные характеристики.

Таблица 4 – Средние значения и медианы 13 столбцов по 716 строкам

Характеристика	Среднее / медиана	Характеристика	Среднее / медиана
Соотношение матрица–наполнитель	2,921 / 2,900	Плотность, кг/м ³	1973,803 / 1973,063
модуль упругости, ГПа	735,551 / 738,737	Количество отвердителя, м.%	110,467 / 110,283
Содержание эпоксидных групп, %	22,185 / 22,201	Температура вспышки	284,386 / 284,615
Поверхностная плотность, г/м ²	479,425 / 449,052	Модуль при растяжении, ГПа	73,207 / 73,109
Прочность при растяжении, МПа	2464,534 / 2455,556	Потребление смолы, г/м ²	219,343 / 219,478
Угол нашивки, град	45,251 / 90,000	Шаг нашивки	6,857 / 6,862
Плотность нашивки	56,954 / 57,231		

Репрезентативные графики EDA, только train (n=716)



Полные наборы гистограмм, boxplot и scatter-диаграмм сохранены в figures/eda.

Рисунок 1 – Примеры распределений, размаха и связей между характеристиками

2 ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1 Предобработка данных

Сначала проверены названия листов и столбцов, типы значений и уникальность индекса. Таблицы соединены внутренним объединением по общему индексу, после чего индекс удалён. Полученные 1023 строки разделены на 716 строк для разработки и 307 строк только для итоговой проверки. Результат приведён в таблице 5.

Таблица 5 – Проверка и разделение данных

Строк	Полей	Обучение	Отложенная оценка	Пропуски
1023	13	716	307	0

2.1.1 Статистики, выбросы и корреляции

Для каждого столбца рассчитаны основные показатели. Необычными отмечались числа ниже $Q1 - 1,5 IQR$ или выше $Q3 + 1,5 IQR$. Больше всего таких строк найдено по плотности нашивки – 16, количеству отвердителя – 9 и температуре вспышки – 8. Это только повод сравнить два варианта подготовки данных, а не доказательство ошибки.

У количества отвердителя 468 из 716 значений с обозначением «м. %» превышают 100. Основа процентов в исходных материалах не объяснена, поэтому значения не пересчитывались. Наибольшая парная корреляция 0,119 также рассчитана только по 716 строкам для обучения.

2.1.2 Распределения до и после нормализации

На рисунках 2–6 значения с разными единицами приведены к общей шкале от 0 до 1. Это нужно только для наглядного сравнения графиков. При обучении Ridge к общему масштабу приводятся входные характеристики, а для SVR и MLP – и входные характеристики, и прогнозируемое значение. Деревья используют исходные числа.

На рисунке 2 показаны соотношение компонентов, плотность и входной столбец «модуль упругости, ГПа». Левый график содержит исходные числа, правый – те же числа на шкале от 0 до 1. Порядок строк и форма распределения при таком преобразовании сохраняются.

Распределения train до и после нормализации, n=716




Рисунок 2 – Распределения до и после нормализации: Соотношение матрица-наполнитель; Плотность, кг/м3; модуль упругости, ГПа

На рисунке 3 показаны количество отвердителя, содержание эпоксидных групп и температура вспышки. Общая шкала облегчает сравнение формы распределений, но не меняет смысл столбцов и не устраняет длинные края распределения.

Распределения train до и после нормализации, n=716




Рисунок 3 – Распределения до и после нормализации: Количество отвердителя, м.%; Содержание эпоксидных групп,%_2; Температура вспышки, C_2

На рисунке 4 показаны поверхностная плотность и два свойства, которые прогнозируются отдельно. Их единицы и диапазоны различаются. Перевод на общую шкалу сделан только для рисунка и не объединяет эти свойства в одну задачу.

Распределения train до и после нормализации, n=716




Рисунок 4 – Распределения до и после нормализации: Поверхностная плотность, г/м²; Модуль упругости при растяжении, ГПа; Прочность при растяжении, МПа

На рисунке 5 показаны потребление смолы и угол нашивки. В таблице угол имеет только два значения – 0° и 90°. Поэтому по этим данным нельзя судить о промежуточных углах.

Распределения train до и после нормализации, n=716




Рисунок 5 – Распределения до и после нормализации: Потребление смолы, г/м2;
Угол нашивки, град

На рисунке 6 показаны шаг и плотность нашивки. Единицы этих столбцов не указаны, поэтому их физический смысл нельзя уточнить по предоставленным материалам. Преобразование сохраняет порядок значений и служит только для сравнения графиков.

Распределения train до и после нормализации, n=716




Рисунок 6 – Распределения до и после нормализации: Шаг нашивки; Плотность нашивки

2.1.3 Решения по предобработке

Пропусков в 13 столбцах нет, поэтому заполнять их не потребовалось. Угол нашивки со значениями 0° и 90° кодировался числами 0 и 1. Для Ridge, SVR и MLP приведение к общему масштабу выполняется вместе с обучением модели и не использует проверочные строки. Для деревьев оно не требуется.

Необычные значения проверены двумя способами: модели обучались на всех строках и после удаления строк по правилу IQR. В двух основных задачах фильтр удалял 53 строки и оставлял 663 из 716. В задаче отношения он удалял 61 строку и оставлял 655. Ошибка нейросети RMSE менялась с 0,935319 до 0,937889, то есть не уменьшалась. Фильтрация не улучшила выбранные модели, поэтому итоговый вариант использует все 716 строк.

В таблицах нет сведений о партиях и повторных сериях. Поэтому нельзя проверить, не попали ли близкие образцы одновременно в данные для обучения

и проверки. Это ограничивает выводы об использовании моделей для других материалов.

2.2 Разработка и обучение модели

Для модуля и прочности сравнивались пять методов: прогноз среднего, Ridge, случайный лес, градиентный бустинг и SVR. Для отношения сравнивались прогноз среднего и MLP. Для каждого варианта вычислялась средняя RMSE в десяти проверках; дополнительно записывались MAE и R^2 . После выбора две прямые модели заново обучались на всех 716 строках и один раз проверялись на 307 тестовых строках. Нейросеть обучалась отдельно с ранней остановкой, как описано в разделе 2.4.

Для модуля выбрана модель, которая выдаёт среднее: ни один более сложный метод не уменьшил RMSE. Для прочности наименьшую среднюю RMSE показал бустинг, но его преимущество мало. Он был лучше прогноза среднего только в 4 из 10 проверок. Это не доказывает устойчивого преимущества.

Рисунок 7 показывает проверку моделей модуля и прочности. Сначала 307 строк откладываются для финального теста. Оставшиеся 716 строк десять раз делятся на части для обучения и проверки настроек. После выбора две готовые модели обучаются на всех 716 строках и один раз проверяются на 307 тестовых строках.



В каждом цикле предобработка и модель обучаются заново. Тестовая выборка не участвует в выборе.

Критерий выбора: средняя RMSE – ошибка в единицах свойства, которая сильнее учитывает крупные промахи.

Рисунок 7 – Выбор и итоговая проверка моделей модуля и прочности

2.2.1 Результаты перекрёстной проверки

Таблица 6 содержит результаты перекрёстной проверки до итогового теста. Для модуля выбран прогноз среднего. Для прочности бустинг лишь немного снизил среднюю RMSE и был лучше в 4 из 10 проверок. Для отношения MLP получила RMSE 0,935 против 0,906 у среднего. После знака «±» указано стандартное отклонение результатов десяти проверок.

Таблица 6 – Ключевые результаты десятикратной перекрёстной проверки

Задача	Модель	RMSE, среднее ± разброс	MAE, среднее	R ² , среднее
Модуль, ГПа	Прогноз среднего	3,087 ± 0,257	2,483	-0,015
Прочность, МПа	Прогноз среднего	490,500 ± 24,618	384,750	-0,011
Прочность, МПа	Градиентный бустинг	490,209 ± 23,852	387,225	-0,010
Соотношение, без единицы	Прогноз среднего	0,906 ± 0,047	0,719	-0,008
Соотношение, без единицы	Многослойный персептрон	0,935 ± 0,058	0,751	-0,072

2.3 Тестирование модели

Таблица 7 содержит окончательные результаты на тестовой выборке. Звёздочкой отмечены модели, выбранные до этого теста. RMSE и MAE указаны в единицах свойства, R² единиц не имеет. Ошибки модуля в ГПа и прочности в МПа напрямую не сравниваются.

Таблица 7 – Ошибки моделей для двух прямых задач

Цель	Модель	RMSE, обучение	RMSE, проверка	MAE, проверка	R ² , проверка
Модуль, ГПа	Прогноз среднего*	3,095	3,178	2,556	-0,016
Модуль, ГПа	Гребневая регрессия	3,066	3,190	2,567	-0,024
Модуль, ГПа	Градиентный бустинг	2,867	3,221	2,587	-0,044
Модуль, ГПа	Случайный лес	1,817	3,311	2,643	-0,104
Модуль, ГПа	Метод опорных векторов	2,813	3,263	2,623	-0,072
Прочность, МПа	Прогноз среднего	490,497	473,288	378,984	-0,0003
Прочность, МПа	Гребневая регрессия	485,154	471,726	378,437	0,006
Прочность, МПа	Градиентный бустинг*	447,149	471,410	380,152	0,008
Прочность, МПа	Случайный лес	298,601	476,225	381,814	-0,013
Прочность, МПа	Метод опорных векторов	446,934	484,995	390,329	-0,050

Для модуля выбран прогноз среднего: RMSE 3,178 ГПа, MAE 2,556 ГПа, R² –0,016; сложные методы оказались не лучше. Для прочности бустинг дал RMSE 471,410 МПа против 473,288 МПа у среднего, но его MAE 380,152 МПа хуже 378,984 МПа. R² бустинга 0,008 означает почти полное отсутствие улучшения. Большой разрыв между ошибками случайного леса на обучении и тесте показывает подгонку под обучающие строки.

2.3.1 Фактические и прогнозные значения

На рисунке 8 по горизонтали показаны известные значения, по вертикали – прогнозы. Хорошая модель дала бы точки около диагонали. Для модуля

получилась горизонтальная линия среднего, для прочности – сильный разброс. Значит, модели слабо различают представленные материалы.




Рисунок 8 – Фактические и прогнозные значения модуля и прочности

2.3.2 Анализ остатков

Остаток – это известное значение свойства минус прогноз. На рисунке 9 по горизонтали показан прогноз, по вертикали – остаток. У хорошей модели точки образовали бы узкую полосу около нуля. Здесь полоса широкая и на данных для

обучения, и на тестовых строках. Значит, отдельные прогнозы часто заметно отклоняются от известных значений.




Рисунок 9 – Остатки моделей модуля и прочности на обучающей и отложенной выборках

2.3.3 Какие характеристики использует модель

Чтобы понять, какие характеристики использует модель, один столбец по очереди перемешивают и снова считают RMSE [28]. Если ошибка растёт, этот столбец был полезен для прогноза. На рисунке 10 столбцы вправо от нуля

означают рост ошибки, влево – её снижение. Чёрные отрезки показывают разброс десяти повторов. У прогноза среднего значения равны нулю, потому что он не использует входные характеристики. Оценка роли характеристик помогает объяснить, как модель получает прогноз [18].




Рисунок 10 – Изменение ошибки после перемешивания характеристик

Тестовые строки взяты из тех же исходных таблиц, что и обучающие. Происхождение материалов, партии и повторные испытания неизвестны. Поэтому итог показывает качество только при данном разделении таблицы. Для вывода о других материалах нужны новые независимые данные.

2.4 Нейронная сеть для соотношения матрица–наполнитель

По заданию нейронная сеть оценивает показатель «Соотношение матрица–наполнитель». Она получает остальные 12 характеристик, включая известные модуль и прочность. Сеть восстанавливает записанное значение показателя, а не подбирает состав с заданными свойствами.

Архитектура 12–32–16–1 содержит 12 входов, два внутренних слоя на 32 и 16 нейронов и один ответ; всего в сети 961 настраиваемый параметр. Из 716

обучающих строк 644 использовались для изменения весов, 72 – для ранней остановки. Выполнено 76 эпох, затем восстановлены лучшие веса эпохи 35.

Масштабирование X и y рассчитано до внутреннего разделения 716 строк, поэтому внутренняя кривая не является полностью независимой оценкой. При этом преобразования в десятикратной проверке вычислялись внутри обучающих частей, а внешние 307 строк не участвовали ни в выборе, ни в остановке.

Нейросеть оказалась хуже прогноза среднего. На перекрёстной проверке её RMSE равна 0,935 против 0,906, на итоговой проверке – 0,944 против 0,926; R^2 сети равен $-0,040$. Результаты приведены в таблице 8.

Таблица 8 – Ошибки прогноза среднего и нейронной сети

Модель	RMSE, обучение	RMSE, проверка	MAE, проверка	R^2 , проверка
Прогноз среднего	0,907	0,926	0,752	-0,001
Многослойный персептрон	0,870	0,944	0,777	-0,040

На рисунке 11 слева показано изменение ошибки во время обучения, справа – разброс RMSE в трёх повторах. Более сложная сеть не дала преимуществ, поэтому её результат нельзя использовать как рекомендацию состава.




Рисунок 11 – Диагностика обучения MLP и вариативность перекрёстной проверки при трёх состояниях генератора

2.5 Разработка приложения

Исходное задание разрешает реализовать один или два прогноза из основных задач или отдельной задачи нейронной сети. В приложении выбран разрешённый вариант двух прямых прогнозов: модуля упругости и прочности при растяжении. Пользователь вводит 11 характеристик, программа проверяет значения и применяет две сохранённые модели. Нейронная сеть обучена и проверена как обязательный отдельный эксперимент; её слабый результат остаётся научным выводом, хотя прогноз соотношения не включён в этот интерфейс.

Для значений формы по умолчанию приложение выдаёт 73,2073 ГПа и 2502,06 МПа. Это пример расчёта моделей, а не результат испытания конкретного материала. Команды запуска приведены в README. После запуска приложение открывается по адресу <http://localhost:8501>. Если введённая величина выходит за диапазон обучающих данных, программа предупреждает, что модель не проверялась в этой области.

2.6 Создание удалённого репозитория

Исходный код, данные, модели и документы размещены в открытом репозитории. Профиль: <https://github.com/fpvcstep>. Репозиторий: <https://github.com/fpvcstep/composites-property-prediction>. История изменений: <https://github.com/fpvcstep/composites-property-prediction/commits/main> [20]. Команды запуска и повторения расчётов приведены в README.

ЗАКЛЮЧЕНИЕ

Работа выполнена по единой последовательности от проверки данных до приложения. Две исходные таблицы объединены по индексу. Получены 1023 строки и 13 содержательных столбцов. Для анализа, подготовки и выбора моделей использованы 716 строк, а 307 строк были заранее отделены для однократной итоговой проверки. Пропусков и полных повторов строк не найдено.

Для модуля и прочности использованы 11 входных характеристик: из 13 столбцов исключены оба конечных свойства. Для отдельной задачи соотношения использованы остальные 12 характеристик. Необычные значения были помечены и проверены отдельным вариантом обучения. Фильтрация не уменьшила проверочную ошибку выбранных решений, поэтому для итоговых моделей выбран вариант без удаления строк.

Для модуля ни один испытанный сложный метод не превзошёл прогноз среднего. На тесте RMSE выбранного прогноза равна 3,178 ГПа, MAE – 2,556 ГПа, R^2 – $-0,016$. Для прочности выбран градиентный бустинг, но он оказался лучше среднего только в 4 из 10 проверок. На тесте его RMSE равна 471,410 МПа, MAE – 380,152 МПа, R^2 – $0,008$. Эти результаты не подтверждают высокую практическую точность.

Нейронная сеть оценивала записанное соотношение матрицы и наполнителя по 12 известным характеристикам, включая модуль и прочность. На перекрёстной проверке и на тесте она ошибалась больше прогноза среднего. Поэтому сеть не выбрана как улучшение, а её результат нельзя считать надёжной рекомендацией соотношения компонентов или способом подобрать рецептуру.

В приложении пользователь вводит 11 характеристик и получает два основных прогноза. Интерфейс показывает полный путь от сохранённой модели до ответа, но не заменяет физические испытания. Полученное качество относится к испытанным методам и предоставленным таблицам. Для более надёжных выводов нужны сведения о происхождении материалов и условиях испытаний, а также новые независимые примеры.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1 ASTM International. ASTM D3039/D3039M-17(2025): Standard Test Method for Tensile Properties of Polymer Matrix Composite Materials. 2025. DOI: 10.1520/D3039_D3039M-17R25.

2 International Organization for Standardization. ISO 527-4:2023 Plastics – Determination of tensile properties – Part 4: Test conditions for isotropic and orthotropic fibre-reinforced plastic composites. ISO, 2023. <https://www.iso.org/standard/85809.html>. Дата обращения: 24.09.2026.

3 International Organization for Standardization. ISO 527-5:2021 Plastics – Determination of tensile properties – Part 5: Test conditions for unidirectional fibre-reinforced plastic composites. ISO, 2021. <https://www.iso.org/standard/80370.html>. Дата обращения: 24.09.2026.

4 ASTM International. ASTM D3171-22: Standard Test Methods for Constituent Content of Composite Materials. 2022. DOI: 10.1520/D3171-22.

5 ASTM International. ASTM D5229/D5229M-20: Standard Test Method for Moisture Absorption Properties and Equilibrium Conditioning of Polymer Matrix Composite Materials. 2020. DOI: 10.1520/D5229_D5229M-20.

6 Breiman L. Random Forests. Machine Learning 45, 5–32, 2001. DOI: 10.1023/A:1010933404324.

7 Browning C.E., Husman G.E., Whitney J.M. Moisture Effects in Epoxy Matrix Composites. Composite Materials: Testing and Design (Fourth Conference), ASTM STP 617, 1977, pp. 481–496. DOI: 10.1520/STP26961S.

8 Campbell F.C. Manufacturing Processes for Advanced Composites. Elsevier Science, 2003. DOI: 10.1016/B978-1-85617-415-2.X5000-X.

9 Cawley G.C., Talbot N.L.C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research 11, 2079–2107, 2010. <https://www.jmlr.org/papers/v11/cawley10a.html>. Дата обращения: 24.09.2026.

10 Chicco D., Warrens M.J., Jurman G. The Coefficient of Determination R-squared Is More Informative than SMAPE, MAE, MAPE, MSE and RMSE in Regression Analysis Evaluation. *PeerJ Computer Science* 7:e623, 2021. DOI: 10.7717/peerj-cs.623.

11 Cortes C., Vapnik V. Support-Vector Networks. *Machine Learning* 20, 273–297, 1995. DOI: 10.1007/BF00994018.

12 Drucker H., Burges C.J.C., Kaufman L. et al. Support Vector Regression Machines. *Advances in Neural Information Processing Systems* 9, 1996. <https://papers.nips.cc/paper/1996/hash/d38901788c533e8286cb6400b40b386d-Abstract.html>.
Дата обращения: 24.09.2026.

13 Friedman J.H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics* 29(5), 1189–1232, 2001. DOI: 10.1214/aos/1013203451.

14 Gibson R.F. *Principles of Composite Material Mechanics*. CRC Press, 2016. <https://www.routledge.com/Principles-of-Composite-Material-Mechanics-Fourth-Edition-4th-Edition/Gibson/p/book/9781498720694>. Дата обращения: 24.09.2026.

15 Hoerl A.E., Kennard R.W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics* 12(1), 55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

16 Jones F.R. *Composites Science, Technology, and Engineering*. Cambridge University Press, 2022. DOI: 10.1017/9781139565943.

17 Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. *Proceedings of IJCAI 1995*, 1137–1143. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>. Дата обращения: 24.09.2026.

18 Lundberg S.M., Lee S. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems* 30, 2017. <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>.
Дата обращения: 24.09.2026.

19 Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12, 2825–2830, 2011. <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Дата обращения: 24.09.2026.

20 Pineau J., Vincent-Lamarre P., Sinha K. et al. Improving Reproducibility in Machine Learning Research: A Report from the NeurIPS 2019 Reproducibility Program. *Journal of Machine Learning Research* 22(164), 1–20, 2021. <https://jmlr.org/papers/v22/20-303.html>. Дата обращения: 24.09.2026.

21 Pinnell M., Fields R., Zabora R. Results of an Interlaboratory Study of the ASTM Standard Test Method for Tensile Properties of Polymer Matrix Composites D 3039. *Journal of Testing and Evaluation* 33(1), 2005. DOI: 10.1520/JTE12521.

22 Rumelhart D.E., Hinton G.E., Williams R.J. Learning Representations by Back-propagating Errors. *Nature* 323, 533–536, 1986. DOI: 10.1038/323533a0.

23 Srivastava N., Hinton G., Krizhevsky A. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research* 15, 1929–1958, 2014. <https://www.jmlr.org/papers/v15/srivastava14a.html>. Дата обращения: 24.09.2026.

24 Varma S., Simon R. Bias in Error Estimation When Using Cross-Validation for Model Selection. *BMC Bioinformatics* 7, 91, 2006. DOI: 10.1186/1471-2105-7-91.

25 scikit-learn developers. Common Pitfalls and Recommended Practices. scikit-learn documentation, 2026. https://scikit-learn.org/stable/common_pitfalls.html. Дата обращения: 24.09.2026.

26 scikit-learn developers. GridSearchCV API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. Дата обращения: 24.09.2026.

27 scikit-learn developers. mean_absolute_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html. Дата обращения: 24.09.2026.

28 scikit-learn developers. Permutation Feature Importance. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/permutation_importance.html. Дата обращения: 24.09.2026.

29 scikit-learn developers. `r2_score` API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html. Дата обращения: 24.09.2026.

30 scikit-learn developers. `root_mean_squared_error` API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.root_mean_squared_error.html. Дата обращения: 24.09.2026.