

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
« Наука о данных: профессиональный уровень (Data Science PRO)»

Слушатель

Фролов П.В.

Москва, 2026

СОДЕРЖАНИЕ

Введение.....	3
1 Аналитическая часть.....	4
1.1 Постановка задачи.....	4
1.2 Описание используемых методов.....	5
1.3 Разведочный анализ данных	9
2 Практическая часть	12
2.1 Предобработка данных	12
2.2 Разработка и обучение модели.....	18
2.3 Тестирование модели	19
2.4 Нейронная сеть для соотношения матрица–наполнитель.....	24
2.5 Разработка приложения	25
2.6 Создание удалённого репозитория	25
Заключение.....	26
Библиографический список	27

ВВЕДЕНИЕ

Композиционный материал состоит из нескольких компонентов. Связующее удерживает их вместе; в композитах его также называют матрицей. Наполнитель добавляют, чтобы получить нужные свойства. Он, например, может выполнять армирующую функцию, то есть усиливать материал. Итоговые свойства зависят от сочетания компонентов и способа изготовления, поэтому их нельзя надёжно определить только по свойствам отдельных частей.

В работе используются две таблицы Excel. В каждой строке записан один представленный материал. Для него указаны характеристики состава и изготовления: соотношение связующего и наполнителя, плотность, количество отвердителя, потребление смолы и параметры нашивки. В таблицах также есть известные значения двух конечных свойств. По таким примерам модели учатся связывать характеристики материала с его свойствами.

Нужно прогнозировать два свойства. Модуль упругости при растяжении характеризует жёсткость материала при обратимом растяжении, когда после снятия нагрузки восстанавливается исходная форма. Прочность при растяжении показывает предельное напряжение до разрушения. Напряжение здесь означает нагрузку, делённую на площадь поперечного сечения. Для решения задачи таблицы объединяют и проверяют, а затем данные разделяют на обучающую и тестовую выборки. На первой подбирают модели, а вторую используют только для итоговой проверки. Отдельно по заданию нейронная сеть оценивает соотношение матрицы и наполнителя.

1 АНАЛИТИЧЕСКАЯ ЧАСТЬ

1.1 Постановка задачи

Цель работы – по предоставленным таблицам построить модели для прогноза модуля упругости при растяжении и прочности при растяжении, проверить качество прогнозов и включить выбранные модели в демонстрационное приложение.

Файлы X_br.xlsx и X_nup.xlsx соединены по совпадающему индексу. Индекс нужен только для соединения и не передаётся моделям. Получены 1023 строки и 13 содержательных столбцов. Ещё 17 строк файла X_nup.xlsx не имели пары. Одна строка описывает один представленный материал: его характеристики и известные значения свойств.

Два из 13 столбцов – свойства, которые нужно прогнозировать: «Модуль упругости при растяжении, ГПа» и «Прочность при растяжении, МПа». В этой работе для каждого свойства строится отдельная модель. Оба конечных свойства исключаются из входных данных, поэтому остаётся $13 - 2 = 11$ входных характеристик.

Эти 11 характеристик: соотношение матрицы и наполнителя; плотность; «модуль упругости, ГПа»; количество отвердителя; содержание эпоксидных групп; температура вспышки; поверхностная плотность; потребление смолы; угол нашивки; шаг нашивки; плотность нашивки. Столбец «модуль упругости, ГПа» используется как входная характеристика. «Модуль упругости при растяжении, ГПа» – другое поле и одно из прогнозируемых свойств. Смысл первого столбца в исходных материалах подробно не раскрыт, поэтому эти два поля нельзя считать взаимозаменяемыми.

Для отдельной задачи нейронная сеть оценивает один столбец – «Соотношение матрица–наполнитель». Его исключают, а остальные 12 столбцов оставляют: $13 - 1 = 12$. В эти 12 характеристик входят оба конечных свойства. Поэтому сеть восстанавливает известный показатель по остальным данным, а не подбирает состав материала.

Таблица 1 – Три задачи и число входных характеристик

Свойство или показатель	Число входов	Назначение
1	2	3
Модуль упругости при растяжении, ГПа	11	Прямой прогноз
Прочность при растяжении, МПа	11	Прямой прогноз
Соотношение матрица–наполнитель	12	Отдельная задача нейронной сети

1.2 Описание используемых методов

Свойства композита зависят от состава, расположения компонентов и способа изготовления [8], [14], [16]. Эти сведения могут быть связаны с жёсткостью и прочностью. Модели сравниваются, чтобы проверить, насколько такая связь видна в предоставленных таблицах.

В исходных материалах не объяснено, что именно означает показатель «Соотношение матрица–наполнитель». Его нельзя без дополнительных сведений считать массовой или объёмной долей [4]. Столбец «Температура вспышки» также нельзя называть температурой отверждения.

На результат испытаний могут влиять подготовка образца, направление укладки, закрепление, скорость, влажность и температура [1], [2], [3], [5], [7], [21]. Эти условия для строк таблицы не указаны. Поэтому выводы относятся к предоставленным данным, а не ко всем композиционным материалам.

1.2.1 Прогноз среднего и гребневая регрессия

Сначала задаётся простой ориентир – прогноз среднего. Такая модель не смотрит на характеристики материала и выдаёт всем строкам среднее значение свойства в данных для обучения. Более сложный метод имеет практический смысл только тогда, когда ошибается меньше этого ориентира.

Гребневая регрессия (Ridge) умножает каждую входную характеристику на свой коэффициент, складывает результаты и добавляет постоянную поправку. Коэффициенты подбираются по строкам с известными значениями свойства. Дополнительное ограничение не даёт им становиться чрезмерно большими [15]. Метод реализован средствами `scikit-learn` [19].

Ridge включена в сравнение как простая и понятная модель. Она показывает, достаточно ли суммы отдельных вкладов для прогноза. Перед обучением значения приводятся к сопоставимому масштабу, чтобы столбец с крупными числами не получил преимущество только из-за единиц измерения. Такое приведение каждый раз рассчитывается только по данным для обучения.

1.2.2 Случайный лес и градиентный бустинг

Случайный лес (Random Forest) строит много деревьев решений и усредняет их ответы [6]. Каждое дерево последовательно разделяет строки по значениям характеристик. Так модель может находить связи сложнее простой суммы. Усреднение уменьшает влияние отдельного дерева, но модель труднее объяснять и она плохо работает за пределами уже встречавшихся диапазонов.

Градиентный бустинг (Gradient Boosting) также использует деревья, но строит их по очереди. Каждое новое дерево старается исправить ошибки предыдущих [13]. Такой способ может находить сложные связи, однако слишком большая модель способна запомнить особенности данных для обучения. Поэтому глубину деревьев и скорость исправления ошибок подбирают на проверочных частях.

Главное различие методов показано в таблице 2. Лес усредняет много деревьев, а бустинг исправляет ошибки шаг за шагом.

Таблица 2 – Случайный лес и градиентный бустинг

Метод	Достоинства	Ограничения
1	2	3
Случайный лес	Находит сложные связи, усредняет ответы деревьев	Труднее объяснять; слабый прогноз вне известных диапазонов
Градиентный бустинг	Исправляет ошибки шаг за шагом	Нужен контроль сложности

1.2.3 Метод опорных векторов и многослойный персептрон

Регрессия на опорных векторах (SVR) ищет правило, при котором небольшие отклонения считаются допустимыми, а крупные сильнее увеличивают ошибку [11], [12]. Метод может учитывать сложные связи, но чувствителен к масштабу чисел. Поэтому входные характеристики и прогнозируемое свойство приводятся к сопоставимому масштабу только по данным для обучения.

Многослойный персептрон (MLP) – нейронная сеть для числового прогноза. Она передаёт входные значения через несколько слоёв и меняет веса связей так, чтобы уменьшить ошибку [22], [23]. Сеть может описывать сложную зависимость, но на небольшой таблице легко подстраивается под случайные особенности. Поэтому использованы небольшая сеть, ограничение весов и ранняя остановка.

Для двух основных свойств сравниваются прогноз среднего, Ridge, случайный лес, градиентный бустинг и SVR. Для отдельной задачи отношения сравниваются прогноз среднего и MLP. Победитель заранее не назначается: выбирается модель с меньшей ошибкой на проверочных частях данных.

1.2.4 Как проверялись модели

Из 1023 строк заранее выделены 716 строк для разработки и 307 строк для итоговой проверки. Последние не используются при выборе модели. Внутри 716

строк выполняется десятикратная перекрёстная проверка: данные делят на десять частей, модель учится на девяти и проверяется на десятой. Затем проверочная часть меняется, пока каждая не побывает в этой роли [17].

Для каждой модели заранее задаётся несколько вариантов настроек. Их перебор называют поиском по сетке [26]. Все преобразования чисел заново рассчитываются внутри каждой обучающей части [25]. Настройка выбирается по средней ошибке десяти проверок. Такой порядок не позволяет тестовой выборке повлиять на выбор, но не заменяет проверку на новых материалах [24], [9].

Качество описывают тремя показателями. Средняя абсолютная ошибка (MAE) показывает обычный размер отклонения прогноза от известного значения [27]. Корень из средней квадратичной ошибки (RMSE) выражается в тех же единицах свойства, но сильнее учитывает крупные промахи [30]. Для обеих ошибок меньшее значение лучше.

Коэффициент R^2 сравнивает модель с прогнозом среднего [29], [10]. Значение около нуля означает, что улучшения почти нет. Отрицательное значение означает результат хуже среднего. R^2 не является процентом точности.

Среднее для простого ориентира вычисляется только по данным для обучения. Среднее тестовых строк может немного отличаться. Поэтому R^2 прогноза среднего на тестовой выборке не обязано быть равно нулевым.

Краткий смысл показателей приведён в таблице 3.

Таблица 3 – Метрики регрессии

Метрика	Интерпретация
1	2
RMSE	Ошибка в единицах свойства; крупные промахи влияют сильнее
MAE	Средний размер ошибки в единицах свойства
R^2	Сравнение с прогнозом среднего; это не процент точности

1.3 Разведочный анализ данных

Разведочный анализ данных – это знакомство с таблицей до обучения моделей. Он выполнен только на 716 обучающих строках. Для каждого из 13 столбцов рассчитаны среднее и медиана. Медиана – значение в середине упорядоченного ряда. Результаты приведены в таблице 4. Также построены распределения, диаграммы размаха и 78 графиков для пар столбцов. Пропусков не найдено. Угол нашивки принимает только два значения: 0° у 356 строк и 90° у 360 строк.


Для поиска необычных чисел использован межквартильный размах (IQR). Q1 и Q3 ограничивают среднюю половину упорядоченных значений, а IQR равен расстоянию между ними. Значения далеко за этими границами отмечаются для проверки, но не объявляются ошибками автоматически. Самая большая по модулю парная корреляция равна 0,119 между углом и плотностью нашивки. Это слабая связь. Однако несколько характеристик вместе могут быть полезнее, поэтому окончательный вывод делают по ошибкам моделей.

Рисунок 1 помогает увидеть данные тремя способами. Гистограммы показывают, какие значения встречаются чаще. Диаграммы размаха показывают середину, общий разброс и удалённые точки. На диаграммах рассеяния каждая точка – одна строка таблицы, а её положение задают две выбранные характеристики.

Таблица 4 – Средние значения и медианы 13 столбцов по 716 строкам

Характеристика	Среднее / медиана	Характеристика	Среднее / медиана
1	2	3	4
Соотношение матрица–наполнитель	2,921 / 2,900	Плотность, кг/м ³	1973,803 / 1973,063
модуль упругости, ГПа	735,551 / 738,737	Количество отвердителя, м.%	110,467 / 110,283
Содержание эпоксидных групп, %	22,185 / 22,201	Температура вспышки	284,386 / 284,615
Поверхностная плотность, г/м ²	479,425 / 449,052	Модуль при растяжении, ГПа	73,207 / 73,109
Прочность при растяжении, МПа	2464,534 / 2455,556	Потребление смолы, г/м ²	219,343 / 219,478
Угол нашивки, град	45,251 / 90,000	Шаг нашивки	6,857 / 6,862
Плотность нашивки	56,954 / 57,231		

Репрезентативные графики EDA, только train (n=716)



Полные наборы гистограмм, boxplot и scatter-диаграмм сохранены в figures/eda.

Рисунок 1 – Примеры распределений, размаха и связей между характеристиками

2 ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1 Предобработка данных

Сначала проверены названия листов и столбцов, типы значений и уникальность индекса. Затем таблицы соединены по общему индексу. Полученные 1023 строки разделены случайным образом при состоянии генератора 42: 716 строк использованы для разработки, 307 – только для итоговой проверки. Индекс после соединения удалён. Итоги проверки приведены в таблице 5.

Таблица 5 – Проверка и разделение данных

Строк	Полей	Обучение	Отложенная оценка	Пропуски	Состояние генератора
1	2	3	4	5	6
1023	13	716	307	0	42

2.1.1 Статистики, выбросы и корреляции

Для каждого столбца рассчитаны основные показатели. Необычными отмечались числа ниже $Q1 - 1,5 IQR$ или выше $Q3 + 1,5 IQR$. Больше всего таких строк найдено по плотности нашивки – 16, количеству отвердителя – 9 и температуре вспышки – 8. Это только повод сравнить два варианта подготовки данных, а не доказательство ошибки.

У количества отвердителя 468 из 716 значений с обозначением «м. %» превышают 100. Основа процентов в исходных материалах не объяснена, поэтому значения не пересчитывались. Наибольшая парная корреляция 0,119 также рассчитана только по 716 строкам для обучения.

2.1.2 Распределения до и после нормализации

На рисунках 2–6 значения с разными единицами приведены к общей шкале от 0 до 1. Это нужно только для наглядного сравнения графиков. При обучении Ridge к общему масштабу приводятся входные характеристики, а для SVR и MLP

– и входные характеристики, и прогнозируемое значение. Деревья используют исходные числа.

На рисунке 2 показаны соотношение компонентов, плотность и входной столбец «модуль упругости, ГПа». Левый график содержит исходные числа, правый – те же числа на шкале от 0 до 1. Порядок строк и форма распределения при таком преобразовании сохраняются.

Распределения train до и после нормализации, n=716




Рисунок 2 – Распределения до и после нормализации: Соотношение матрица-наполнитель; Плотность, кг/м3; модуль упругости, ГПа

На рисунке 3 показаны количество отвердителя, содержание эпоксидных групп и температура вспышки. Общая шкала облегчает сравнение формы распределений, но не меняет смысл столбцов и не устраняет длинные края распределения.

Распределения train до и после нормализации, n=716




Рисунок 3 – Распределения до и после нормализации: Количество отвердителя, м.%; Содержание эпоксидных групп,%_2; Температура вспышки, С_2

На рисунке 4 показаны поверхностная плотность и два свойства, которые прогнозируются отдельно. Их единицы и диапазоны различаются. Перевод на общую шкалу сделан только для рисунка и не объединяет эти свойства в одну задачу.

Распределения train до и после нормализации, n=716




Рисунок 4 – Распределения до и после нормализации: Поверхностная плотность, г/м²; Модуль упругости при растяжении, ГПа; Прочность при растяжении, МПа

На рисунке 5 показаны потребление смолы и угол нашивки. В таблице угол имеет только два значения – 0° и 90°. Поэтому по этим данным нельзя судить о промежуточных углах.

Распределения train до и после нормализации, n=716




Рисунок 5 – Распределения до и после нормализации: Потребление смолы, г/м2;
Угол нашивки, град

На рисунке 6 показаны шаг и плотность нашивки. Единицы этих столбцов не указаны, поэтому их физический смысл нельзя уточнить по предоставленным материалам. Преобразование сохраняет порядок значений и служит только для сравнения графиков.

Распределения train до и после нормализации, n=716




Рисунок 6 – Распределения до и после нормализации: Шаг нашивки; Плотность нашивки

2.1.3 Решения по предобработке

Пропусков в 13 столбцах нет, поэтому заполнять их не потребовалось. Угол нашивки со значениями 0° и 90° кодировался числами 0 и 1. Для Ridge, SVR и MLP приведение к общему масштабу выполняется вместе с обучением модели и не использует проверочные строки. Для деревьев оно не требуется.

Необычные значения проверены двумя способами: модели обучались на всех строках и после удаления строк по правилу IQR. В двух основных задачах фильтр удалял 53 строки и оставлял 663 из 716. В задаче отношения он удалял 61 строку и оставлял 655. Ошибка нейросети RMSE менялась с 0,935319 до 0,937889, то есть не уменьшалась. Фильтрация не улучшила выбранные модели, поэтому итоговый вариант использует все 716 строк.

В таблицах нет сведений о партиях и повторных сериях. Поэтому нельзя проверить, не попали ли близкие образцы одновременно в данные для обучения

и проверки. Это ограничивает выводы об использовании моделей для других материалов.

2.2 Разработка и обучение модели

Для модуля и прочности сравнивались пять методов: прогноз среднего, Ridge, случайный лес, градиентный бустинг и SVR. Для отношения сравнивались прогноз среднего и MLP. Для каждого варианта вычислялась средняя RMSE в десяти проверках; дополнительно записывались MAE и R^2 . После выбора две прямые модели заново обучались на всех 716 строках и один раз проверялись на 307 тестовых строках. Нейросеть обучалась отдельно с ранней остановкой, как описано в разделе 2.4.

Для модуля выбрана модель, которая выдаёт среднее: ни один более сложный метод не уменьшил RMSE. Для прочности наименьшую среднюю RMSE показал бустинг, но его преимущество мало. Он был лучше прогноза среднего только в 4 из 10 проверок. Это не доказывает устойчивого преимущества.

Рисунок 7 показывает проверку моделей модуля и прочности. Сначала 307 строк откладываются для финального теста. Оставшиеся 716 строк десять раз делятся на части для обучения и проверки настроек. После выбора две готовые модели обучаются на всех 716 строках и один раз проверяются на 307 тестовых строках.



В каждом цикле предобработка и модель обучаются заново. Тестовая выборка не участвует в выборе.

Критерий выбора: средняя RMSE – ошибка в единицах свойства, которая сильнее учитывает крупные промахи.

Рисунок 7 – Выбор и итоговая проверка моделей модуля и прочности

2.2.1 Результаты перекрёстной проверки

Таблица 6 содержит результаты перекрёстной проверки до итогового теста. Для модуля выбран прогноз среднего. Для прочности бустинг лишь немного снизил среднюю RMSE и был лучше в 4 из 10 проверок. Для отношения MLP получила RMSE 0,935 против 0,906 у среднего. После знака «±» указано стандартное отклонение результатов десяти проверок.

Таблица 6 – Ключевые результаты десятикратной перекрёстной проверки

Задача	Модель	RMSE, среднее ± раз- брос	MAE, среднее	R ² , среднее
1	2	3	4	5
Модуль, ГПа	Прогноз среднего	3,087 ± 0,257	2,483	-0,015
Прочность, МПа	Прогноз среднего	490,500 ± 24,618	384,750	-0,011
Прочность, МПа	Градиентный бустинг	490,209 ± 23,852	387,225	-0,010
Соотно- шение, без единицы	Прогноз среднего	0,906 ± 0,047	0,719	-0,008
Соотно- шение, без единицы	Многослойный персептрон	0,935 ± 0,058	0,751	-0,072

2.3 Тестирование модели

Таблица 7 содержит окончательные результаты на тестовой выборке. Звёздочкой отмечены модели, выбранные до этого теста. RMSE и MAE указаны в единицах свойства, R² единиц не имеет. Ошибки модуля в ГПа и прочности в МПа напрямую не сравниваются.

Таблица 7 – Ошибки моделей для двух прямых задач

Цель	Модель	RMSE, обу- чение	RMSE, проверка	MAE, проверка	R ² , проверка
1	2	3	4	5	6
Модуль, ГПа	Про- гноз сред- него*	3,095	3,178	2,556	-0,016
Модуль, ГПа	Гребневая регрессия	3,066	3,190	2,567	-0,024
Модуль, ГПа	Градиентный бустинг	2,867	3,221	2,587	-0,044
Модуль, ГПа	Случайный лес	1,817	3,311	2,643	-0,104
Модуль, ГПа	Метод опор- ных векто- ров	2,813	3,263	2,623	-0,072
Прочность, МПа	Про- гноз сред- него	490,497	473,288	378,984	-0,0003
Прочность, МПа	Гребневая регрессия	485,154	471,726	378,437	0,006
Прочность, МПа	Градиентный бустинг*	447,149	471,410	380,152	0,008
Прочность, МПа	Случайный лес	298,601	476,225	381,814	-0,013
Прочность, МПа	Метод опор- ных векто- ров	446,934	484,995	390,329	-0,050

Для модуля выбран прогноз среднего: RMSE 3,178 ГПа, MAE 2,556 ГПа, R² –0,016; сложные методы оказались не лучше. Для прочности бустинг дал RMSE 471,410 МПа против 473,288 МПа у среднего, но его MAE 380,152 МПа хуже 378,984 МПа. R² бустинга 0,008 означает почти полное отсутствие

улучшения. Большой разрыв между ошибками случайного леса на обучении и тесте показывает подгонку под обучающие строки.

2.3.1 Фактические и прогнозные значения

На рисунке 8 по горизонтали показаны известные значения, по вертикали – прогнозы. Хорошая модель дала бы точки около диагонали. Для модуля получилась горизонтальная линия среднего, для прочности – сильный разброс. Значит, модели слабо различают представленные материалы.




Рисунок 8 – Фактические и прогнозные значения модуля и прочности

2.3.2 Анализ остатков

Остаток – это известное значение свойства минус прогноз. На рисунке 9 по горизонтали показан прогноз, по вертикали – остаток. У хорошей модели точки образовали бы узкую полосу около нуля. Здесь полоса широкая и на данных для обучения, и на тестовых строках. Значит, отдельные прогнозы часто заметно отклоняются от известных значений.




Рисунок 9 – Остатки моделей модуля и прочности на обучающей и отложенной выборках

2.3.3 Какие характеристики использует модель

Чтобы понять, какие характеристики использует модель, один столбец по очереди перемешивают и снова считают RMSE [28]. Если ошибка растёт, этот столбец был полезен для прогноза. На рисунке 10 столбцы вправо от нуля означают рост ошибки, влево – её снижение. Чёрные отрезки показывают разброс десяти повторов. У прогноза среднего значения равны нулю, потому что он не использует входные характеристики. Оценка роли характеристик помогает объяснить, как модель получает прогноз [18].




Рисунок 10 – Изменение ошибки после перемешивания характеристик

Тестовые строки взяты из тех же исходных таблиц, что и обучающие. Происхождение материалов, партии и повторные испытания неизвестны. Поэтому итог показывает качество только при данном разделении таблицы. Для вывода о других материалах нужны новые независимые данные.

2.4 Нейронная сеть для соотношения матрица–наполнитель

По заданию нейронная сеть оценивает показатель «Соотношение матрица–наполнитель». Она получает остальные 12 характеристик, включая известные модуль и прочность. Сеть восстанавливает записанное значение показателя, а не подбирает состав с заданными свойствами.

Структура 12–32–16–1 означает 12 входных чисел, два внутренних слоя из 32 и 16 элементов и один ответ. Один полный просмотр обучающих строк называется эпохой. Отдельная внутренняя часть данных помогала вовремя остановить обучение. Выполнено 76 эпох, затем восстановлены лучшие веса эпохи 35.

Общий масштаб чисел рассчитан до внутреннего разделения 716 строк, поэтому внутренняя кривая не является полностью независимой проверкой. Десятикратная проверка и 307 тестовых строк оставались отделены от обучения.

Нейросеть оказалась хуже прогноза среднего. На перекрёстной проверке её RMSE равна 0,935 против 0,906, на тестовой – 0,944 против 0,926; R^2 сети равен –0,040. Итоговые числа приведены в таблице 8. На рисунке 11 слева показан ход обучения, справа – разброс RMSE в трёх повторах. Результат сети нельзя использовать как рекомендацию состава.

Таблица 8 – Ошибки прогноза среднего и нейронной сети

Модель	RMSE, обучение	RMSE, проверка	MAE, проверка	R^2 , проверка
1	2	3	4	5
Прогноз среднего	0,907	0,926	0,752	-0,001
Много- слойный пер- септрон	0,870	0,944	0,777	-0,040




Рисунок 11 – Диагностика обучения MLP и вариативность перекрёстной проверки при трёх состояниях генератора

2.5 Разработка приложения

Приложение показывает работу двух основных моделей. Пользователь вводит 11 характеристик, программа проверяет значения и выдаёт прогноз модуля и прочности при растяжении. Нейросеть для отношения в приложение не включена. Для значений формы по умолчанию получены 73,2073 ГПа и 2502,06 МПа. Это пример работы интерфейса, а не результат испытания конкретного материала.

Команды запуска приведены в README. После запуска приложение открывается в браузере по адресу <http://localhost:8501>. Пользователь заменяет значения формы и нажимает кнопку «Прогноз». Если значение выходит за диапазон, встречавшийся при обучении, программа предупреждает, что модель не проверялась в этой области.

2.6 Создание удалённого репозитория

Исходный код, данные, модели и документы размещены в открытом репозитории. Профиль: <https://github.com/fpvcstep>. Репозиторий: <https://github.com/fpvcstep/composites-property-prediction>. История изменений: <https://github.com/fpvcstep/composites-property-prediction/commits/main> [20]. Команды запуска и повторения расчётов приведены в README.

ЗАКЛЮЧЕНИЕ

В работе две исходные таблицы объединены и проверены. Получены 1023 строки и 13 содержательных столбцов. Для разработки моделей использованы 716 строк, для итоговой проверки – 307. Пропусков и полных повторов строк не найдено.

Для модуля и прочности использованы 11 входных характеристик: из 13 столбцов исключены оба конечных свойства. Для отдельной задачи отношения использованы остальные 12 характеристик. Удаление необычных строк не улучшило результат, поэтому в итоговом варианте они сохранены.

Для модуля ни один испытанный сложный метод не превзошёл прогноз среднего. Для прочности выбран градиентный бустинг, но он оказался лучше среднего только в 4 из 10 проверок. Итоговые ошибки приведены в таблицах 6 и 7. Они показывают, что высокая практическая точность не подтверждена.

Нейронная сеть оценивала соотношение матрицы и наполнителя по 12 известным характеристикам, включая модуль и прочность. Она ошибалась больше прогноза среднего. Поэтому результат сети нельзя считать надёжной рекомендацией соотношения компонентов или способом подобрать рецептуру.

Приложение позволяет ввести 11 характеристик и получить два основных прогноза. Эти значения показывают работу моделей, но не заменяют испытания. Полученное качество относится к испытанным методам и предоставленным таблицам. Для более надёжных выводов нужны сведения о происхождении материалов и условиях испытаний, а также новые независимые примеры.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1 ASTM International. ASTM D3039/D3039M-17(2025): Standard Test Method for Tensile Properties of Polymer Matrix Composite Materials. 2025. DOI: 10.1520/D3039_D3039M-17R25.

2 International Organization for Standardization. ISO 527-4:2023 Plastics – Determination of tensile properties – Part 4: Test conditions for isotropic and orthotropic fibre-reinforced plastic composites. ISO, 2023. <https://www.iso.org/standard/85809.html>. Дата обращения: 24.09.2026.

3 International Organization for Standardization. ISO 527-5:2021 Plastics – Determination of tensile properties – Part 5: Test conditions for unidirectional fibre-reinforced plastic composites. ISO, 2021. <https://www.iso.org/standard/80370.html>. Дата обращения: 24.09.2026.

4 ASTM International. ASTM D3171-22: Standard Test Methods for Constituent Content of Composite Materials. 2022. DOI: 10.1520/D3171-22.

5 ASTM International. ASTM D5229/D5229M-20: Standard Test Method for Moisture Absorption Properties and Equilibrium Conditioning of Polymer Matrix Composite Materials. 2020. DOI: 10.1520/D5229_D5229M-20.

6 Breiman L. Random Forests. Machine Learning 45, 5–32, 2001. DOI: 10.1023/A:1010933404324.

7 Browning C.E., Husman G.E., Whitney J.M. Moisture Effects in Epoxy Matrix Composites. Composite Materials: Testing and Design (Fourth Conference), ASTM STP 617, 1977, pp. 481–496. DOI: 10.1520/STP26961S.

8 Campbell F.C. Manufacturing Processes for Advanced Composites. Elsevier Science, 2003. DOI: 10.1016/B978-1-85617-415-2.X5000-X.

9 Cawley G.C., Talbot N.L.C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research 11, 2079–2107, 2010. <https://www.jmlr.org/papers/v11/cawley10a.html>. Дата обращения: 24.09.2026.

10 Chicco D., Warrens M.J., Jurman G. The Coefficient of Determination R-squared Is More Informative than SMAPE, MAE, MAPE, MSE and RMSE in Regression Analysis Evaluation. *PeerJ Computer Science* 7:e623, 2021. DOI: 10.7717/peerj-cs.623.

11 Cortes C., Vapnik V. Support-Vector Networks. *Machine Learning* 20, 273–297, 1995. DOI: 10.1007/BF00994018.

12 Drucker H., Burges C.J.C., Kaufman L. et al. Support Vector Regression Machines. *Advances in Neural Information Processing Systems* 9, 1996. <https://papers.nips.cc/paper/1996/hash/d38901788c533e8286cb6400b40b386d-Abstract.html>.
Дата обращения: 24.09.2026.

13 Friedman J.H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics* 29(5), 1189–1232, 2001. DOI: 10.1214/aos/1013203451.

14 Gibson R.F. *Principles of Composite Material Mechanics*. CRC Press, 2016. <https://www.routledge.com/Principles-of-Composite-Material-Mechanics-Fourth-Edition-4th-Edition/Gibson/p/book/9781498720694>. Дата обращения: 24.09.2026.

15 Hoerl A.E., Kennard R.W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics* 12(1), 55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

16 Jones F.R. *Composites Science, Technology, and Engineering*. Cambridge University Press, 2022. DOI: 10.1017/9781139565943.

17 Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. *Proceedings of IJCAI 1995*, 1137–1143. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>. Дата обращения: 24.09.2026.

18 Lundberg S.M., Lee S. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems* 30, 2017. <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>.
Дата обращения: 24.09.2026.

19 Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12, 2825–2830, 2011. <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Дата обращения: 24.09.2026.

20 Pineau J., Vincent-Lamarre P., Sinha K. et al. Improving Reproducibility in Machine Learning Research: A Report from the NeurIPS 2019 Reproducibility Program. *Journal of Machine Learning Research* 22(164), 1–20, 2021. <https://jmlr.org/papers/v22/20-303.html>. Дата обращения: 24.09.2026.

21 Pinnell M., Fields R., Zabora R. Results of an Interlaboratory Study of the ASTM Standard Test Method for Tensile Properties of Polymer Matrix Composites D 3039. *Journal of Testing and Evaluation* 33(1), 2005. DOI: 10.1520/JTE12521.

22 Rumelhart D.E., Hinton G.E., Williams R.J. Learning Representations by Back-propagating Errors. *Nature* 323, 533–536, 1986. DOI: 10.1038/323533a0.

23 Srivastava N., Hinton G., Krizhevsky A. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research* 15, 1929–1958, 2014. <https://www.jmlr.org/papers/v15/srivastava14a.html>. Дата обращения: 24.09.2026.

24 Varma S., Simon R. Bias in Error Estimation When Using Cross-Validation for Model Selection. *BMC Bioinformatics* 7, 91, 2006. DOI: 10.1186/1471-2105-7-91.

25 scikit-learn developers. Common Pitfalls and Recommended Practices. scikit-learn documentation, 2026. https://scikit-learn.org/stable/common_pitfalls.html. Дата обращения: 24.09.2026.

26 scikit-learn developers. GridSearchCV API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. Дата обращения: 24.09.2026.

27 scikit-learn developers. mean_absolute_error API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html. Дата обращения: 24.09.2026.

28 scikit-learn developers. Permutation Feature Importance. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/permutation_importance.html. Дата обращения: 24.09.2026.

29 scikit-learn developers. `r2_score` API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html. Дата обращения: 24.09.2026.

30 scikit-learn developers. `root_mean_squared_error` API Reference. scikit-learn documentation, 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.root_mean_squared_error.html. Дата обращения: 24.09.2026.